



Universidade Estadual de Campinas
Instituto de Computação



Gabriel Henriques Siqueira

Problemas de Partição e Rearranjo de Genomas
Considerando Regiões Intergênicas e Genes
Multiplicados

CAMPINAS

1500

Gabriel Henriques Siqueira

**Problemas de Partição e Rearranjo de Genomas Considerando
Regiões Intergênicas e Genes Multiplicados**

Tese apresentada ao Instituto de Computação
da Universidade Estadual de Campinas como
parte dos requisitos para a obtenção do título
de Doutor em Ciência da Computação.

Orientador: Prof. Dr. Zanoni Dias

Coorientador: Dr. Alexsandro Oliveira Alexandrino

Este exemplar corresponde à versão da Tese
entregue à banca antes da defesa.

CAMPINAS

1500

Na versão final esta página será substituída pela ficha catalográfica.

De acordo com o padrão da CCPG: “Quando se tratar de Teses e Dissertações financiadas por agências de fomento, os beneficiados deverão inserir no formulário de solicitação da ficha catalográfica as informações sobre agência e número do processo pelo qual receberam o auxílio, porém essa informação não ficará visível na ficha, será utilizada para fins estatísticos. Os auxílios recebidos devem também ser citados na seção “Agradecimento” seguindo os padrões exigidos pelas agências de fomento.”

e

“caso a tese de doutorado seja feita em Cotutela, será necessário informar na ficha catalográfica o fato, a Universidade conveniente, o país e o nome do orientador.”

Na versão final, esta página será substituída por outra informando a composição da banca e que a ata de defesa está arquivada pela Unicamp.

Agradecimentos

Resumo

Abstract

Lista de Figuras

2.1	Um genoma $\mathcal{G}$ composto por três cromossomos.	17
2.2	Dois genomas $\mathcal{G}$ e $\mathcal{H}$ com exemplos de rótulos abundantes e raros.	18
2.3	Um cromossomo $\mathcal{C}$ seguido do subcromossomo $\mathcal{C}_{[2,5]}$ e seu inverso $inv(\mathcal{C}_{[2,5]})$	18
2.4	O grafo de adjacência entre dois genomas $\mathcal{G}$ e $\mathcal{H}$	21
2.5	Exemplo de reversão.	23
2.6	Exemplo de transposição.	24
2.7	Exemplo de DCJ.	25
2.8	Exemplo de inserção.	26
2.9	Exemplo de deleção.	27
2.10	A partição de um cromossomo $\mathcal{C}$	29
2.11	Uma partição direta comum entre dois genomas $\mathcal{G}$ e $\mathcal{H}$	29
2.12	Uma partição reversa comum entre dois genomas $\mathcal{G}$ e $\mathcal{H}$	30
3.1	Algumas componentes de um grafo de compatibilidade parcial de blocos.	42
3.2	Execução do algoritmo de $2k$ -aproximação para PDCMG e PRCMG	48

Lista de Tabelas

3.1	Fatores de aproximação para os problemas de rearranjo de genomas. . . .	40
-----	---	----

Sumário

1	Introdução	12
1.1	NP-Dificuldade e Abordagens para o Desenvolvimento de Algoritmos . . .	13
1.2	Revisão Bibliográfica	13
1.2.1	Rearranjos em Permutações	13
1.2.2	Repetição de Genes	14
1.2.3	Múltiplos Cromossomos	14
1.2.4	Representação de Regiões Intergênicas	14
2	Fundamentação Teórica	15
2.1	Sequências e Grafos	15
2.2	Representação de Genomas	16
2.3	Operações de Rearranjo de Genomas	22
2.4	Partições de Genomas	28
2.5	Equivalência entre Correspondência de Genes, Empacotamentos por Ciclos e Partições Guiadas	31
3	Partição de Genomas	35
3.1	Relações entre Problemas de Partição de Genomas e Problemas de Rear- ranjo de Genomas	35
3.2	Balanceamento de Genomas	39
3.3	Algoritmo de aproximação para Problemas de Partição de Genomas Ba- lanceados	41
3.4	Algoritmo Parametrizado para Problemas de Partição de Genomas	47
3.5	Heurísticas para Problemas de Partição de Genomas	47

4	Empacotamento Máximo do Grafo de Adjacências por Ciclos Alternados	49
4.1	Heurísticas para o Problema de Empacotamento Máximo do Grafo de Adjacências por Ciclos Alternados	49
4.1.1	Algoritmos de Empacotamento	49
4.1.2	Empacotamento Aleatório	50
4.1.3	Algoritmo Genético	50
5	Conclusão	51

Capítulo 1

Introdução

Existem várias formas de se representar um genoma com base nas características que desejamos codificar na representação. Por exemplo, podemos optar por incluir informações sobre a orientação dos genes, sobre regiões intergênicas ou sobre a estrutura dos cromossomos. Também existem restrições que podem ou não ser impostas, como a proibição de genes com múltiplas cópias ou genomas com conjuntos de genes distintos.

Os rearranjos de genomas são mutações que afetam sequências de DNA, alterando a ordem e orientação dos genes, ou até mesmo a estrutura dos cromossomos. Em problemas de distância de rearranjos, estamos interessados em uma sequência de rearranjos capazes de transformar um genoma em outro. Em particular, adotando um critério de parcimônia, buscamos a sequência de rearranjos mais curta possível. Esses rearranjos podem ser classificados em conservativos e não conservativos, dependendo se preservam ou não o número de cópias de cada gene no genoma. Quando consideramos apenas rearranjos conservativos, os genomas sendo comparados devem ser formados pelo mesmo conjunto de genes.

Diversos levantamentos bibliográficos foram publicados descrevendo as diferentes representações dos genomas e os principais problemas de rearranjos e algoritmos desenvolvidos para resolvê-los. Em 2009, um livro foi publicado por Fertin e coautores [22] descrevendo as principais resultados da área até aquela data. Outros levantamentos mais recentes atualizam esses resultados, como o de Elmabrouk e Sankoff [26] em 2012 e o de Zeira e Shamir [43] em 2019, ambos focados em representações que permitem a repetição de genes. Também temos o levantamento de Bhatia e coautores [11] em 2016, que apresenta uma visão geral de como os genomas podem ser representados. Adicionalmente, o levantamento de Bulteau e Weller [18] em 2019, contém uma seção dedicada a algoritmos parametrizados para problemas de distância de rearranjos. Outro levantamento foi o de Oliveira e coautores [28] em 2024, que foca em problemas de rearranjos com apenas uma cópia de cada gene, mas considerando operações com restrições ou pesos e a inclusão das regiões intergênicas na representação dos genomas.

1.1 NP-Dificuldade e Abordagens para o Desenvolvimento de Algoritmos

1.2 Revisão Bibliográfica

1.2.1 Rearranjos em Permutações

Nos primeiros trabalhos da área, os problemas de distância de rearranjos assumiam que os genomas possuíam apenas uma cópia de cada gene, e que os rearranjos eram conservativos. Nesses trabalhos, os genomas eram representados como permutações de inteiros, onde cada inteiro representa um gene.

O primeiro evento a ser explorado foi a reversão (ou inversão), que inverte a ordem de uma subsequência de genes. Watterson e coautores [40] foram os primeiros a proporem um problema de distância de rearranjos envolvendo esse evento. Em 1999, Caprara [19] provou que o problema de distância de rearranjos com o evento de reversões em permutações pertence a classe de problemas NP-difíceis. Um resultado mais forte foi provado por Berman e Karpinski [10], também em 1999, que demonstraram que o problema está na classe MAX-SNP-difícil. Partindo do algoritmo de aproximação inicial com fator 2 proposto por Kececioğlu e Sankoff [25] em 1993, uma sequência de melhorias na aproximação levaram a um algoritmo com fator de aproximação de 1.375 proposto por Berman e coautores [9] em 2002.

Em 1996, Bafna e Pevzner [6] incorporaram informações sobre a orientação dos genes, sendo que essa variação do problema pode ser resolvida de forma exata em tempo polinomial, conforme demonstrado por Hannenhalli e Pevzner [24] em 1999. Posteriormente outros trabalhos reduziram a complexidade assintótica desse algoritmo [23, 38], foi inclusive proposto um algoritmo capaz de resolver o problema em tempo linear caso não seja necessário recuperar a sequência exata de operações [5].

Outro evento estudado nos trabalhos iniciais de rearranjos foi a transposição, que troca a posição de duas subsequências consecutivas de genes. O problema de distância de rearranjos com o evento de transposição em permutações foi proposto por Bafna e Pevzner [7] em 1998 junto com a descrição de um algoritmo com fator de aproximação 1.5 e, em 2021, Bultheau e coautores [17] provaram que o problema pertence a classe NP-difícil. Outros algoritmos de aproximação foram propostas chegando a um fator de 1.375 proposto por Elias e Hartman [21] em 2006. Posteriormente, um problema foi encontrado com a garantia de aproximação desse algoritmo, o uma correção foi proposta [36] com um algoritmo de complexidade $O(n^6)$. Em seguida a complexidade assintótica do algoritmo corrigido foi melhorada para $O(n^5)$ [1].

Os eventos de reversão e transposição também foram estudados em conjunto. Em 1998, Walter e coautores [39] propuseram o problema de distância de rearranjos em permutações com ambos os eventos, além de descreverem algoritmos com fatores de aproximação 2 para o caso com sinais, e 3 para o caso sem sinais. Em 2019, Oliveira e coautores [29] provaram que o problema com e sem sinais pertence a classe NP-difícil. A aproximação do problema sem sinais foi melhorada por Rahman e coautores [33], em 2008, para um fator de $2k$, onde k é a aproximação para o problema de decomposição de ciclos considerando

um tipo particular de grafo, chamado de grafo de ciclos, bastante utilizado em algoritmos para problemas de rearranjos, o menor valor de k conhecido até o momento é $1.4167 + \epsilon$ encontrado por Chen [20] em 2013, resultando em um algoritmo com fator de aproximação $2.8334 + \epsilon$.

1.2.2 Repetição de Genes

1.2.3 Múltiplos Cromossomos

1.2.4 Representação de Regiões Intergênicas

Capítulo 2

Fundamentação Teórica

Este capítulo tem como propósito definir os conceitos utilizados nesta tese.

2.1 Sequências e Grafos

Nesta tese utilizamos a notação convencional $c \in C$ e $|C|$ para elementos c pertencentes a um conjunto C e para o tamanho do conjunto C , respectivamente. Em alguns casos vamos utilizar multiconjuntos, onde podem haver elementos repetidos. Se os elementos de um multiconjunto apresentam uma ordem relevante, utilizaremos a notação $C = (C_1, C_2, \dots, C_{|C|})$, denotando o i -ésimo elemento do multiconjunto C , segundo essa ordem, por C_i . Nesse caso, dizemos que esse multiconjunto é uma *sequência*. Algumas sequências serão tratadas como circulares, e nesse caso assumimos que $C_i = C_j$, se $i = ((j - 1) \bmod |C|) + 1$, ou seja após o último elemento da sequência o índice volta a se referir ao primeiro. Para facilitar as definições vamos supor que todas as operações com índices de sequências circulares são feitas respeitando essa equivalência. Se uma sequência não for circular, então ela é linear. Dizemos que duas sequências lineares C e C' são iguais (denotado por $C = C'$) se $|C| = |C'|$ e $C_i = C'_i, \forall i : 1 \leq i \leq |C|$. No caso em que C e C' são circulares, essas sequências são iguais se $|C| = |C'|$ e existe um valor $d \in \{0, \dots, |C| - 1\}$, tal que $C_i = C'_{i+d}, \forall i : 1 \leq i \leq |C|$. Chamamos esse valor de *deslocamento* e denotamos por $Des(C, C') = \{d \in \{0, \dots, |C| - 1\} : C_i = C'_{i+d}, \forall i : 1 \leq i \leq |C|\}$ o conjunto dos deslocamentos válidos. Para sequências lineares, o único deslocamento possível é $d = 0$.

Nesta tese, um *grafo* é um par $G = (V, E)$, com um conjunto de *vértices* V e um conjunto de *arestas* E , tal que E é um conjunto com pares não ordenados de elementos de V . Ou seja, se $\{v, u\} \in E$ então $v \in V, u \in V$ e $\{u, v\} = \{v, u\}$. Normalmente, visualizamos os vértices como pontos e as arestas como ligações entre esses pontos. Um *caminho* de tamanho n em um grafo é uma sequência $(v_1, \dots, v_n)$ de vértices, tal que nenhum vértice se repete e $\{v_i, v_{i+1}\} \in E, \forall i : 1 \leq i \leq n - 1$. Um caminho é um *ciclo* se $\{v_n, v_1\} \in E$. Dizemos que as arestas entre vértices consecutivos de um caminho ou ciclo pertencem a esse caminho ou ciclo.

Um *subgrafo* de um grafo $G = (V, E)$ é um grafo $G' = (V', E')$, tal que V' é um subconjunto de V e E' é um subconjunto de E que contém apenas arestas que conectam

vértices de V' . Um subgrafo induzido por um conjunto de vértices V' é um subgrafo $G' = (V', E')$ onde E' contém todas as arestas entre vértices de V' . Uma *componente conexa* de um grafo é um subgrafo induzido maximal onde existe um caminho entre quaisquer dois vértices de V' . Ou seja, não é possível adicionar mais vértices a V' sem perder a propriedade de que existe um caminho entre quaisquer dois vértices de V' .

Dado um grafo $G = (V, E)$, dizemos que G é bipartido se pudermos separar V em dois conjuntos disjuntos V^1 e V^2 , de modo que nenhuma aresta de E conecte dois vértices do mesmo conjunto. Um grafo bipartido G admite um emparelhamento perfeito se existir uma bijeção f de V^1 para V^2 , tal que todo vértice $v \in V^1$ esteja conectado por uma aresta a um vértice $f(v) \in V^2$.

Uma cobertura de vértices de um grafo $G = (V, E)$ é um subconjunto V' de V , tal que qualquer aresta em E é incidente a pelo menos um vértice de V' . O problema da Cobertura Mínima de Vértices busca uma cobertura de tamanho mínimo e é um problema NP-difícil, que admite um algoritmo de aproximação com fator 2. Esse algoritmo consiste em iterativamente selecionar uma aresta ainda não coberta e incluir ambos os vértices incidentes a ela em V' , até que uma cobertura seja encontrada [32].

Um conjunto independente de um grafo $G = (V, E)$ é um subconjunto V' de V , tal que nenhum par de vértices em V' é conectado por uma aresta. O problema do Conjunto Independente Máximo busca um conjunto independente de tamanho máximo. Encontrar tal conjunto também é um problema NP-difícil, e é NP-difícil aproximá-lo com um fator de $|V|^{1-\epsilon}$, para qualquer número real positivo ϵ [44]. Um conjunto independente pode ser construído a partir de uma cobertura de vértices selecionando todos os vértices que não pertencem à cobertura. Note que maximizar o tamanho de um conjunto independente é equivalente a minimizar o tamanho da cobertura de vértices correspondente.

2.2 Representação de Genomas

Vamos representar um *genoma* $\mathcal{G}$ por um multiconjunto de cromossomos. Cada *cromossomo* $\mathcal{C} \in \mathcal{G}$ é representado por um par $(S, \check{S})$, onde S é uma sequência de genes e $\check{S}$ é uma estrutura adicional representando informações sobre regiões intergênicas. Cada gene de S é representado por um caractere com um sinal $+$ ou $-$, representando a orientação do gene. Em alguns casos precisamos representar genomas para os quais não conhecemos as orientações dos genes, nesses caso, os sinais são omitidos e dizemos que temos uma *representação sem sinais*. Quando estamos considerando os sinais dizemos que temos uma *representação com sinais*.

Os caracteres usados para representar os genes, ignorando os sinais, são chamados de *rótulos*, e o conjunto de todos os rótulos de um genoma $\mathcal{G}$ é chamado de *alfabeto* e denotado por $\Sigma_{\mathcal{G}}$. Normalmente, utilizamos uma sequência de inteiros como $\check{S}$, onde o i -ésimo inteiro representa o tamanho da i -ésima região intergênica (quantidade de nucleotídios nessa região). Quando utilizarmos outra estrutura para as regiões intergênicas, iremos especificá-la antes. Considerando essa representação, quando nos referimos a uma *sequência de material genético* estamos nos referindo a uma sequência intercalada genes e regiões intergênicas de um cromossomo.




Figura 2.1: Um genoma $\mathcal{G}$ composto por três cromossomos $\mathcal{C}_1 = (S_1, \check{S}_1)$, $\mathcal{C}_2 = (S_2, \check{S}_2)$ e $\mathcal{C}_3 = (S_3, \check{S}_3)$. Esses cromossomos são representados pelas seguintes listas de caracteres (genes) e inteiros (regiões intergênicas): $S_1 = (\#, +B, \#)$, $\check{S}_1 = (2, 1)$, $S_2 = (+A, -B)$, $\check{S}_2 = (2, 1)$, $S_3 = (\#, -C, -A, +A, \#)$ e $\check{S}_3 = (1, 4, 2, 2)$. $\mathcal{C}_1$ e $\mathcal{C}_3$ são cromossomos lineares e $\mathcal{C}_2$ é um cromossomo circular.

Nossa representação inclui genomas circulares e lineares. No caso de *cromossomos lineares* existem regiões intergênicas entre os genes e nas extremidades do cromossomo. Nesse caso adicionamos dois caracteres $\#$ no começo e no fim do cromossomo (esses caracteres não recebem sinais e assumimos que $-\# = \#$), para simplificação de algumas definições. Seguindo a correspondência com conceitos biológicos, chamamos esses caracteres adicionados nas extremidades dos cromossomos de telômeros e os trataremos como genes. Com esses novos caracteres, podemos considerar que todas as regiões intergênicas estão entre genes. No caso de *cromossomos circulares*, a região intergênica entre o último gene e o primeiro gene é a mesma, sendo essa a última região intergênica de $\check{S}$. Levando em conta essa distinção, temos $|S| = |\check{S}| + 1$ em genomas lineares e $|S| = |\check{S}|$ em genomas circulares. Para genomas circulares, as sequências de genes e de regiões intergênicas são consideradas circulares. Na Figura 2.1 temos um exemplo de um genoma codificado pela representação adotada nesta tese.

A *ocorrência* de um rótulo α em um cromossomo $\mathcal{C}$, respectivamente em um genoma $\mathcal{G}$, é o número de caracteres em $\mathcal{C}$, respectivamente $\mathcal{G}$, que possuem esse rótulo. O valor de ocorrência é denotado por $occ(\alpha, \mathcal{C})$, respectivamente $occ(\alpha, \mathcal{G})$, e o maior valor de ocorrência considerando qualquer α é a ocorrência máxima denotada por $occ_max(\mathcal{C})$, respectivamente $occ_max(\mathcal{G})$. Quando temos dois genomas $\mathcal{G}$ e $\mathcal{H}$ (como na Figura 2.2), dizemos que um rótulo α é:

- *abundante* em $\mathcal{G}$, se $occ(\alpha, \mathcal{G}) > occ(\alpha, \mathcal{H})$;
- *abundante* em $\mathcal{H}$, se $occ(\alpha, \mathcal{G}) < occ(\alpha, \mathcal{H})$;
- *raro* em $\mathcal{G}$, se $occ(\alpha, \mathcal{G}) \leq occ(\alpha, \mathcal{H})$;
- *raro* em $\mathcal{H}$, se $occ(\alpha, \mathcal{G}) \geq occ(\alpha, \mathcal{H})$.

Dois genomas $\mathcal{G}$ e $\mathcal{H}$ são *balanceados* se as ocorrências de todos os rótulos são iguais em ambos os genomas, ou seja $occ(\alpha, \mathcal{G}) = occ(\alpha, \mathcal{H})$, $\forall \alpha \in \Sigma_{\mathcal{G}} \cup \Sigma_{\mathcal{H}}$. Em particular, essa condição implica $\Sigma_{\mathcal{G}} = \Sigma_{\mathcal{H}}$.

A seguir apresentamos algumas relações úteis entre cromossomos.

Dado um cromossomo $\mathcal{C} = (S, \check{S})$, um subcromossomo de $\mathcal{C}$ é o próprio $\mathcal{C}$ ou uma sequência de genes e regiões intergênicas, denotada por $\mathcal{C}_{[i,j]}$, $1 \leq i, j \leq |S|$, construída de acordo com os seguintes dois casos:




Figura 2.2: Dois genomas $\mathcal{G}$ e $\mathcal{H}$. O rótulo $\#$ é abundante em $\mathcal{G}$ e raro em $\mathcal{H}$, os demais rótulos são raros em ambos.




Figura 2.3: Um cromossomo $\mathcal{C}$ seguido do subcromossomo $\mathcal{C}_{[2,5]}$ e seu inverso $inv(\mathcal{C}_{[2,5]})$.

- Se $i \leq j$ então $\mathcal{C}_{[i,j]}$ é composto pelos genes S_k , com $i \leq k \leq j$, e pelas regiões intergênicas $\check{S}_\ell$, com $i \leq \ell < j$.
- Se $j < i$ então $\mathcal{C}$ deve ser um cromossomo circular e $\mathcal{C}_{[i,j]}$ é composto pelos genes S_k , com $i \leq k \leq |S|$, pelos genes S_ℓ , com $1 \leq \ell \leq j$, pelas regiões intergênicas $\check{S}_p$, com $i \leq p \leq |S|$, e pelas regiões intergênicas $\check{S}_q$, com $1 \leq q < j$.

Usamos a notação $\mathcal{C}' \subseteq \mathcal{C}$ para indicar que $\mathcal{C}'$ é um subcromossomo de $\mathcal{C}$. Iremos tratar subcromossomos como cromossomos, a única diferença é que eles podem não ter telômeros. Inclusive podemos ter subcromossomos de subcromossomos.

O *inverso* de um cromossomo $\mathcal{C} = (S, \check{S})$ é um cromossomo $inv(\mathcal{C}) = (P, \check{P})$, tal que $P_i = -S_{|S|-i+1}, \forall i : 1 \leq i \leq |S|$, e $\check{P}_i = \check{S}_{|\check{S}|-i}, \forall i : 1 \leq i \leq |S|$. Note que em cromossomos circulares a transformação dos índices implica que a região intergênica entre o primeiro e último gene se mantém na mesma posição. Se o cromossomo não tiver sinais então o inverso também não terá sinais, ou seja $P_i = S_{|S|-i+1}, \forall i : 1 \leq i \leq |S|$. Essas relações entre cromossomos estão exemplificadas na Figura 2.3.

Dizemos que dois cromossomos são iguais se suas strings e listas de regiões intergênicas são iguais e, no caso de cromossomos circulares essas sequências podem ser rotacionadas com o mesmo deslocamento até serem iguais (Por exemplo, os cromossomos circulares $((+A, +B, -B), (1, 2, 3))$ e $((+B, -B, +A), (2, 3, 1))$ são iguais). Dados dois cromossomos $\mathcal{C} = (S, \check{S})$ e $\mathcal{C}' = (S', \check{S}')$ uma relação de compatibilidade completa, denotada por $\approx_C$, é usada para generalizar a noção de igualdade adicionando mais flexibilidade. A relação $\mathcal{C} \approx_C \mathcal{C}'$ deve satisfazer as seguintes propriedades:

- $S = S'$.

- Existe um deslocamento $d \in Des(S, S')$, tal que $\mathcal{C}_{[i,j]} \approx_C \mathcal{C}'_{[i+d,j+d]}, \forall i, j : 1 \leq i, j \leq |S|$.

Se $\mathcal{C} \approx_C \mathcal{C}'$ dizemos que $\mathcal{C}$ é *completamente compatível* com $\mathcal{C}'$. Também temos a relação de compatibilidade parcial, $\approx_P$, derivada da $\approx_C$. Dizemos que $\mathcal{C} \approx_P \mathcal{C}'$ se $\mathcal{C} \approx_C \mathcal{C}'$ ou $inv(\mathcal{C}) \approx_C \mathcal{C}'$. Se $\mathcal{C} \approx_P \mathcal{C}'$ dizemos que $\mathcal{C}$ é *parcialmente compatível* com $\mathcal{C}'$. Quando o tipo de compatibilidade pode ser inferido pelo contexto ou quando uma afirmação é válida para genomas parcialmente e completamente compatíveis, dizemos apenas que os genomas são compatíveis, chamamos a relação de compatibilidade e usamos a notação $\approx$.

Alguns exemplos de relações de compatibilidade entre dois cromossomos $\mathcal{C} = (S, \check{S})$ e $\mathcal{C}' = (P, \check{P})$ são:

- A relação trivial: $\mathcal{C} \approx_C \mathcal{C}'$ se $S = P$. Para essa relação, somente ignoramos as regiões intergênicas. Por exemplo, temos:

$$((\#, +A, +B, \#), (1, 1, 3)) \approx_C ((\#, +A, +B, \#), (1, 2, 3))$$

$$((\#, +A, +B, \#), (1, 1, 3)) \approx_P ((\#, -B, -A, \#), (1, 2, 3))$$

- A relação de igualdade: $\mathcal{C} \approx_C \mathcal{C}'$ se $\mathcal{C} = \mathcal{C}'$. Por exemplo, temos:

$$((+A, -B, +C), (1, 2, 3)) \approx_C ((-B, +C, +A), (2, 3, 1))$$

$$((+A, -B, +C), (1, 2, 3)) \approx_P ((-C, +B, -A), (2, 1, 3))$$

- A relação de ϵ -compatibilidade: $\mathcal{C} \approx_C \mathcal{C}'$ se $S = P$ e $|\check{P}_{i+d} - \check{S}_i| \leq \epsilon, \forall i : 1 \leq i \leq |\check{S}|, d \in Des(S, P)$. Essa relação permite um erro de ϵ ao comparar as regiões intergênicas. Note que com $\epsilon = 0$, essa relação se torna a relação de igualdade e com um ϵ suficientemente grande, essa relação se torna a relação trivial. Além disso, essa relação (e consequentemente as anteriores) é simétrica, pois $\mathcal{C} \approx_C \mathcal{C}'$ se e somente se $\mathcal{C}' \approx_C \mathcal{C}$. Por exemplo, para $\epsilon = 2$, temos:

$$((\#, +A, +B, \#), (1, 2, 3)) \approx_C ((\#, +A, +B, \#), (3, 3, 1))$$

$$((+A, +B, +C), (2, 3, 1)) \approx_P ((-C, -B, -A), (2, 4, 0))$$

- A relação de intervalo: Para cada região intergênica $\check{P}_i$ associamos um intervalo $[\check{P}_i^{min}, \check{P}_i^{max}]$, tal que $\check{P}_i^{min} \leq \check{P}_i \leq \check{P}_i^{max}$. Então temos $\mathcal{C} \approx_C \mathcal{C}'$ se $S = P$ e $\check{P}_i^{min} \leq \check{S}_{i+d} \leq \check{P}_i^{max}, \forall i : 1 \leq i \leq |\check{S}|, d \in Des(S, P)$. A relação ϵ -compatível é um caso particular dessa relação onde usamos o intervalo $[\check{P}_i - \epsilon, \check{P}_i + \epsilon]$ para todas as regiões intergênicas $\check{P}_i$. Note que essa relação não é simétrica. Nesse caso costumamos descrever a região intergênica $\check{P}_i$ de P como $\check{P}_i^{min} : \check{P}_i^{max}$ para representar o intervalo permitido para essa região. Por exemplo, temos:

$$((\#, +A, +B, \#), (1, 2, 3)) \approx_C ((\#, +A, +B, \#), (1 : 2, 1 : 3, 3 : 4))$$

$$((\#, +A, +B, \#), (1, 2, 3)) \approx_P ((\#, -B, -A, \#), (3 : 4, 1 : 3, 1 : 2))$$

Dizemos que dois genomas são completamente compatíveis se existe uma bijeção entre seus cromossomos, tal que os cromossomos correspondentes são completamente compatíveis.

Nossa próxima definição será mais simples se assumirmos que os genomas têm o mesmo número de cromossomos lineares. Para mantermos nossa definição geral, se temos genomas com números diferentes de cromossomos lineares podemos adicionar cromossomos lineares vazios (ou seja, cromossomos lineares com apenas os caracteres de telômeros e uma região intergênica com valor zero entre eles) para igualar o número de cromossomos lineares. Assim, a definição a seguir é válida para qualquer par de genomas.

Uma forma alternativa de pensar em um gene S_i é como um par de *extremidades* (S_i^h, S_i^t) , se S_i tiver um sinal $+$, ou (S_i^t, S_i^h) , se S_i tiver um sinal $-$. Não utilizamos sinais ao representar as extremidades. Excepcionalmente os telômeros são vistos como apenas uma extremidade $\#$. O símbolo $\#$ e os símbolos S_i^t e S_i^h , para todo caractere S_i , são chamados de *rótulos das extremidades*. Com essa representação, dado um par de caracteres S_i e S_{i+1} de algum cromossomo $\mathcal{C} = (S, \check{S})$ podemos definir uma *adjacência* como um dos seguintes pares:

- (S_i^t, S_{i+1}^h) , se S_i e S_{i+1} tiverem sinal $+$;
- (S_i^h, S_{i+1}^t) , se S_i e S_{i+1} tiverem sinal $-$;
- (S_i^t, S_{i+1}^t) , se S_i tiver um sinal $+$ e S_{i+1} tiver um sinal $-$;
- (S_i^h, S_{i+1}^h) , se S_i tiver um sinal $-$ e S_{i+1} tiver um sinal $+$;
- se S_i ou S_{i+1} for um telômero ($\#$) considere o caso correspondente sem o sobrescrito h ou t .

Note que a região intergênica $\check{S}_i$ está entre as extremidades dessa adjacência.

A relação entre dois genomas $\mathcal{G}$ e $\mathcal{H}$, com o mesmo número de cromossomos lineares, é representada pelo *grafo de adjacências* $\mathbb{AG}(\mathcal{G}, \mathcal{H}) = (V, E, w)$, definido por um conjunto de vértices V , um conjunto de arestas E (separado em três conjuntos E_a , E_c e E_r) e uma função $w : E_a \rightarrow \mathbb{N}$, atribuindo pesos às arestas de E_a . O conjunto V é formado pelas extremidades de cada caractere dos genomas $\mathcal{G}$ e $\mathcal{H}$. Note que caracteres de mesmo rótulo dão origem a vértices distintos. O conjunto E_a contém as *arestas de adjacência* que conectam cada par de extremidades correspondentes a uma adjacência. O conjunto E_c contém as *arestas de caractere* que conectam cada par de extremidades correspondentes a um mesmo caractere. Os telômeros não apresentam arestas de caractere. O conjunto E_r contém as *arestas de rótulo* que conectam cada vértice vindo de $\mathcal{G}$ com cada vértice vindo de $\mathcal{H}$ com o mesmo rótulo de extremidade. A função w atribui a cada aresta de E_a um peso igual ao tamanho da região intergênica entre as extremidades conectadas por essa aresta. Dois vértices são gêmeos se eles correspondem ao mesmo gene (ou seja, são as extremidades X^t e X^h de um gene X). Duas arestas de rótulo são *gêmeas* se elas conectam dois pares de vértices gêmeos. A Figura 2.4 apresenta um exemplo de um grafo de adjacências.

Esse grafo também pode ser usado para genomas sem sinais, mas apresenta duas variações possíveis. Podemos assumir que todos os genes têm o sinal positivo ou podemos




Figura 2.4: O grafo de adjacência entre dois genomas $\mathcal{G}$ e $\mathcal{H}$. As arestas de adjacência são representadas por linhas contínuas retas, as arestas de caractere são representadas por arcos e as arestas de rótulo são representadas por linhas tracejadas. Algumas arestas de rótulo gêmeas estão marcadas em azul.

conectar todos os rótulos de extremidade X^h e X^t de genomas distintos com arestas de rótulo. A primeira variação é mais simples, mas só é utilizada quando não considerarmos eventos de rearranjo que podem trocar a orientação dos genes. Quando a orientação dos genes pode ser invertida, a segunda variação é mais adequada, pois sem os sinais não guardamos a informação sobre a orientação e essa representação não força uma orientação preestabelecida para os genes.

Um *ciclo alternado* do grafo de adjacências é um ciclo que alterna entre arestas de adjacência e arestas que podem ser de caractere ou de rótulo. Um ciclo alternado é *trivial* se ele contém apenas duas arestas de rótulo e *pequeno* se ele contém até seis arestas de rótulo. Um ciclo alternado é *sujo*, se ele possui pelo menos uma aresta de caractere. Caso contrário dizemos que o ciclo é *limpo*.

Um ciclo alternado trivial e limpo contém uma aresta de adjacência de $\mathcal{G}$, uma aresta de adjacência de $\mathcal{H}$ e duas arestas de rótulo. Essas duas arestas de adjacência determinam, respectivamente, um subcromossomo de dois caracteres em $\mathcal{G}$ e um subcromossomo de dois caracteres em $\mathcal{H}$. O ciclo é *completamente compatível*, respectivamente *parcialmente compatível*, se esses subcromossomos forem completamente, respectivamente parcialmente, compatíveis segundo o alinhamento representado pelas arestas de rótulo do ciclo. Usaremos o termo *ciclo alternado compatível*, quando o tipo de compatibilidade pode ser inferido pelo contexto ou quando uma afirmação é válida para os dois casos.

A representação por grafos de adjacências adotada nesta tese foi apresentada de forma geral o bastante para incluir informações sobre genes faltantes e regiões intergênicas, além de ser apresentada de uma forma que facilite as demais definições que usam essa representação como base. Entretanto, existem outras formas equivalentes ou mais específicas de se representar um par de genomas por um grafo. Por exemplo, a primeira representação que utiliza essa ideia foi a do grafo de breakpoints [6], que representava apenas genomas com uma cópia de cada gene. Além disso, existe o grafo de ciclos [7] que é uma variação

do grafo de breakpoints utilizada em outros problemas de rearranjos, particularmente quando temos genomas sem sinais. Foi nesses grafos que a ideia de adicionar pesos para representar as regiões intergênicas foi introduzida [30]. A representação pelo grafo de adjacências em si foi proposta inicialmente para esse caso, em que cada gene tem apenas uma cópia [8], e originalmente os vértices representavam as adjacências. Depois esse grafo foi adaptado para permitir múltiplas cópias de cada gene [35]. Na representação adotada nesta tese, os vértices representam as extremidades dos genes e as arestas de adjacência conectando essas extremidades representam as adjacências.

No grafo de adjacências, as arestas de adjacência são usadas para representar a ordem dos genes nos genomas, as arestas de rótulo são usadas para relacionar os dois genomas associando os genes que têm o mesmo rótulo e as arestas de caractere são usadas para representar cada caractere e eventualmente ajudar na seleção de caracteres que deverão ser inseridos ou removidos dos genomas. Essas arestas de caractere são uma das opções de adaptação do grafo para lidar com genomas não balanceados, outras adaptações incluem rotular as arestas de adjacência [4] ou adicionar novos vértices e arestas de adjacência, no que chamamos de adjacências fantasmas [34]. Optamos por usar arestas de caractere, pois essa adaptação funciona bem com genes apresentando múltiplas cópias e é uma representação que facilita a descrição dos algoritmos propostos na tese.

2.3 Operações de Rearranjo de Genomas

Os rearranjos de genomas são representados por operações que afetam a ordem e orientação do material genético, além de poder inserir ou remover material genético no caso de rearranjos não conservativos. Utilizaremos o símbolo $\circ$ para denotar a aplicação de uma operação representando um rearranjo γ em um genoma $\mathcal{G}$, ou seja, o genoma resultante será denotado por $\gamma \circ \mathcal{G}$. As operações de rearranjo aplicadas a um genoma $\mathcal{G}$ também podem ser vistas como uma transformação das arestas de adjacência conectando as extremidades de $\mathcal{G}$ no grafo $\text{AG}(\mathcal{G}, \mathcal{H})$.

Inicialmente, definimos duas operações que representam rearranjos conservativos afetando apenas um cromossomo $\mathcal{C} = (S, \check{S})$ de um genoma $\mathcal{G}$. Nessas definições temos o valor $\text{fim}(\mathcal{C})$, que é diferente dependendo se $\mathcal{C}$ é linear ou circular. Assim garantimos que as extremidades com $\#$ não serão afetadas.

$$\text{fim}(\mathcal{C}) = \begin{cases} |S| - 1 & \text{se } \mathcal{C} \text{ é linear} \\ |S| & \text{se } \mathcal{C} \text{ é circular} \end{cases}$$

A operação de *reversão* representa um rearranjo que inverte uma sequência de material genético de um cromossomo. Considere um cromossomo $\mathcal{C} = (S, \check{S})$ de um genoma $\mathcal{G}$, as adjacências $a = (S_i, S_{i+1})$ e $a' = (S_j, S_{j+1})$, e inteiros x e y , tal que:

- $1 \leq i \leq \text{fim}(\mathcal{C})$, $1 \leq j \leq \text{fim}(\mathcal{C})$ e $i \neq j$;
- $0 \leq x \leq \check{S}_i$ e $0 \leq y \leq \check{S}_j$;
- se $\mathcal{C}$ é um cromossomo linear então $i < j$.




Figura 2.5: A representação de uma reversão genérica seguida da aplicação da reversão $\rho_{((S_2, S_3), (S_6, S_7))}^{(a, a')}$ aplicada em um genoma $\mathcal{G} = \{\mathcal{C}\} = \{(S, \check{S})\}$ resultando em um genoma $\mathcal{G}'$. Também são apresentados os grafos $\mathbb{AG}(\mathcal{G}, \mathcal{H})$ e $\mathbb{AG}(\mathcal{G}', \mathcal{H})$. As arestas afetadas pela operação estão em vermelho.

A operação de reversão $\rho_{(\mathcal{C}, x, y)}^{(a, a')}$ quebra o genoma na região $\check{S}_i$ depois de x nucleotídios e na região $\check{S}_j$ depois de y nucleotídios, e reconecta as partes resultantes invertendo a sequência de material genético entre essas quebras. No grafo de adjacências, essa operação remove duas arestas de adjacência (a aresta conectando uma extremidade de S_i com uma extremidade de S_{i+1} e a aresta conectando uma extremidade de S_j com uma extremidade de S_{j+1}) e adiciona duas novas arestas de adjacência. Uma aresta adicionada conecta uma extremidade de S_i com uma extremidade de S_j , essa aresta recebe peso $x + y$, e a outra aresta conecta uma extremidade de S_{i+1} com uma extremidade de S_{j+1} , essa aresta recebe peso $\check{S}_i + \check{S}_j - x - y$. Em ambos os casos, consideramos as extremidades conectadas às arestas removidas. A Figura 2.5 apresenta um exemplo de uma operação de reversão. Note que em uma representação com sinais essa operação inverte os sinais dos genes afetados.

A operação de *transposição* representa um rearranjo que troca a posição de duas sequências consecutivas de material genético de um cromossomo. Considere um cromossomo $\mathcal{C} = (S, \check{S})$ de um genoma $\mathcal{G}$, as adjacências $a = (S_i, S_{i+1})$, $a' = (S_j, S_{j+1})$ e $a'' = (S_k, S_{k+1})$, e inteiros x , y e z , tal que:

- $1 \leq i \leq fim(\mathcal{C})$, $1 \leq j \leq fim(\mathcal{C})$ e $1 \leq k \leq fim(\mathcal{C})$;
- $i < j < k$, $j < k < i$ ou $k < i < j$;
- $0 \leq x \leq \check{S}_i$, $0 \leq y \leq \check{S}_j$ e $0 \leq z \leq \check{S}_k$;
- se $\mathcal{C}$ é um cromossomo linear então $i < j < k$.

A operação de transposição $\tau_{(\mathcal{C}, x, y, z)}^{(a, a', a'')}$ quebra o genoma na região $\check{S}_i$ depois de x nucleotídios, na região $\check{S}_j$ depois de y nucleotídios e na região $\check{S}_k$ depois de z nucleotídios, e reconecta as partes resultantes trocando a posição das sequências de material genético entre essas quebras. No grafo de adjacências, essa operação remove três arestas de adjacência (a aresta conectando uma extremidade de S_i com uma extremidade de S_{i+1} , a aresta conectando uma extremidade de S_j com uma extremidade de S_{j+1} e a aresta conectando uma extremidade de S_k com uma extremidade de S_{k+1}) e adiciona três novas




Figura 2.6: A representação de uma transposição genérica seguida da aplicação da transposição $\tau_{((S_1, S_2), (S_3, S_4), (S_7, S_8))}^{(C, 2, 1, 1)}$ aplicada em um genoma $\mathcal{G} = \{C\} = \{(S, S')\}$ resultando em um genoma $\mathcal{G}'$. Também são apresentados os grafos $\mathcal{AG}(\mathcal{G}, \mathcal{H})$ e $\mathcal{AG}(\mathcal{G}', \mathcal{H})$. As arestas afetadas pela operação estão em vermelho.

arestas de adjacência. Uma aresta adicionada conecta uma extremidade de S_i com uma extremidade de S_{j+1} , essa aresta recebe peso $x + \check{S}_j - y$, outra aresta conecta uma extremidade de S_j com uma extremidade de S_{k+1} , essa aresta recebe peso $y + \check{S}_k - z$, e outra aresta conecta uma extremidade de S_k com uma extremidade de S_{i+1} , essa aresta recebe peso $z + \check{S}_i - x$. Em ambos os casos, consideramos as extremidades conectadas as arestas removidas. A Figura 2.6 apresenta um exemplo de uma operação de transposição.

Vamos agora ver a operação de “double-cut-and-join” (DCJ) que pode afetar mais de um cromossomo. Essa operação quebra o genoma em dois pontos presentes em regiões intergênicas e reconecta esses pontos de diferentes formas. Considere dois cromossomos $\mathcal{C} = (S, \check{S})$ e $\mathcal{C}' = (S', \check{S}')$ de um genoma $\mathcal{G}$ (podemos ter $\mathcal{C} = \mathcal{C}'$), as adjacências $a = (S_i, S_{i+1})$ e $a' = (S'_j, S'_{j+1})$, e inteiros x, y e t , tal que:

- $1 \leq i \leq fim(\mathcal{C})$, $1 \leq j \leq fim(\mathcal{C}')$ e se $\mathcal{C} = \mathcal{C}'$ temos $i \neq j$;
- $0 \leq x \leq \check{S}_i$ e $0 \leq y \leq \check{S}'_j$;
- t é 1 ou 2.

A operação de DCJ $\delta_{(\mathcal{C}, \mathcal{C}', x, y, t)}^{(a, a')}$ quebra o genoma na região $\check{S}_i$ depois de x nucleotídios e na região $\check{S}'_j$ depois de y nucleotídios, e reconecta as partes resultantes, tal que a forma como elas são conectadas depende do valor de t . Considere que $\mathcal{C}$ é quebrado em A e B e $\mathcal{C}'$ é quebrado em C e D (essas partes não são necessariamente distintas). Se $t = 1$ então A é conectado com C e B é conectado com D . Se $t = 2$ então A é conectado com D e B é conectado com C . No grafo de adjacências, essa operação remove duas arestas de adjacência (a aresta conectando uma extremidade de S_i com uma extremidade de S_{i+1} e a aresta conectando uma extremidade de S'_j com uma extremidade de S'_{j+1}) e adiciona duas novas arestas de adjacência. Se $t = 1$, uma aresta adicionada conecta uma extremidade de S_i com uma extremidade de S'_j , essa aresta recebe peso $x + y$, e a outra aresta conecta uma extremidade de S_{i+1} com uma extremidade de S'_{j+1} , essa aresta recebe peso $\check{S}_i + \check{S}'_j - x - y$. Se $t = 2$, uma aresta adicionada conecta uma extremidade de S_i com uma extremidade de S'_{j+1} , essa aresta recebe peso $x + \check{S}'_j - y$, e a outra aresta conecta uma extremidade de S_{i+1} com uma extremidade de S'_j , essa aresta recebe peso $\check{S}_i - x + y$. Em todos os casos




Figura 2.7: A representação de um DCJ genérico seguido das aplicações das operações DCJ $\delta_{(C,C'',0,1,2)}^{((S_1,S_2),(S'_3,S'_4))}$, $\delta_{(C,C'',0,1,1)}^{((S_1,S_2),(S'_3,S'_4))}$ e $\delta_{(C',C'',1,2,2)}^{((S'_1,S'_2),(S''_2,S''_3))}$ aplicados em um genoma $\mathcal{G} = \{C, C', C''\} = \{(S, \check{S}), (S', \check{S}'), (S'', \check{S}'')\}$ resultando nos genomas $\mathcal{G}'$, $\mathcal{G}''$ e $\mathcal{G}'''$, respectivamente. Também são apresentados os grafos $\mathbb{AG}(\mathcal{G}, \mathcal{H})$, $\mathbb{AG}(\mathcal{G}', \mathcal{H})$, $\mathbb{AG}(\mathcal{G}'', \mathcal{H})$ e $\mathbb{AG}(\mathcal{G}''', \mathcal{H})$. As arestas afetadas pela operação estão em vermelho.

consideramos as extremidades conectadas as arestas removidas. A Figura 2.7 apresenta um exemplo de uma operação de DCJ.

Quando um DCJ separa um cromossomo em dois cromossomos, chamamos essa operação de *fissão* e quando um DCJ junta dois cromossomos em um cromossomo, chamamos essa operação de *fusão*. Note que uma reversão $\rho_{(C,x,y)}^{((S_i,S_{i+1}),(S_j,S_{j+1}))}$ é equivalente a um DCJ $\delta_{(C,C,x,y,1)}^{((S_i,S_{i+1}),(S_j,S_{j+1}))}$. Além disso, uma transposição $\tau_{(C,x,y,z)}^{((S_i,S_{i+1}),(S_j,S_{j+1}),(S_k,S_{k+1}))}$ é equivalente a uma sequência de dois dcjs $\delta_{(C,C,x,y,2)}^{((S_i,S_{i+1}),(S_j,S_{j+1}))}$ e $\delta_{(C',C'',z,\check{S}_i-x,1)}^{((S_k,S_{k+1}),(S_{i+1},S_j))}$, onde C' e C'' são os cromossomos resultantes da primeira operação contendo $\check{S}_i$ e $\check{S}_{i+1}$, respectivamente.

Até agora as operações não eram capazes de adicionar ou remover material genético, esses rearranjos são chamados de conservativos. Vamos ver agora dois rearranjos não conservativos. A inserção insere uma sequência de genes e regiões intergênicas. Considere um cromossomo $\mathcal{C} = (S, \check{S})$ de um genoma $\mathcal{G}$, a adjacência $a = (S_i, S_{i+1})$, uma sequência de material genético $\mathcal{C}' = (S', \check{S}')$ (um cromossomo linear sem telômeros) e inteiros x e y , tal que:

- $1 \leq i \leq fim(\mathcal{C})$;




Figura 2.8: A representação de uma inserção genérica seguida da aplicação da inserção $\phi_{(1,4)}^{(\mathcal{C}, (S_2, S_3), ((+B, -C), (5)))}$ aplicada em um genoma $\mathcal{G} = \{\mathcal{C}\} = \{(S, \check{S})\}$ resultando em um genoma $\mathcal{G}'$. Também são apresentados os grafos $\mathbb{AG}(\mathcal{G}, \mathcal{H})$ e $\mathbb{AG}(\mathcal{G}', \mathcal{H})$. As arestas afetadas pela operação estão em vermelho.

- $0 \leq x$ e $0 \leq y$;
- $\check{S}_i \leq x + y$.

A operação de inserção $\phi_{(x,y)}^{(\mathcal{C}, a, \mathcal{C}')}$ insere a sequência $\mathcal{C}'$ entre os genes S_i e S_{i+1} , colocando regiões intergênicas com valores x e y ao redor de $\mathcal{C}'$. No grafo de adjacências, essa operação remove a aresta de adjacência conectando uma extremidade de S_i com uma extremidade de S_{i+1} e adiciona novos vértices, arestas de adjacência e arestas de caractere correspondentes ao cromossomo $\mathcal{C}'$. Também é inserida uma aresta de adjacência conectando uma extremidade de S_i com uma extremidade de $S'_{|S'|}$, essa aresta recebe peso x , e uma outra aresta de adjacência conectando uma extremidade de S_{i+1} com uma extremidade de $S'_{|S'|}$, essa aresta recebe peso y . Em ambos os casos, consideramos as extremidades conectadas as arestas removidas. Além disso, devemos inserir novas arestas de rótulo conectando os novos vértices aos vértices correspondentes no outro genoma usado para construir o grafo. Quando $\mathcal{C}'$ é um cromossomo vazio, a inserção apenas insere regiões intergênicas entre os genes S_i e S_{i+1} mantendo a aresta de adjacência entre eles. A Figura 2.8 apresenta um exemplo de uma operação de inserção.

A deleção remove uma sequência de genes e regiões intergênicas. Considere um cromossomo $\mathcal{C} = (S, \check{S})$ de um genoma $\mathcal{G}$, as adjacências $a = (S_i, S_{i+1})$ e $a' = (S_j, S_{j+1})$, e um inteiro x , tal que:

- $1 \leq i \leq \text{fim}(\mathcal{C})$ e $1 \leq j \leq \text{fim}(\mathcal{C})$;
- $0 \leq x \leq \check{S}_i + \check{S}_j$;
- se $\mathcal{C}$ é um cromossomo linear então $i \leq j$.

A operação de deleção $\psi_{(x)}^{(\mathcal{C}, a, a')}$ remove os genes e regiões intergênicas entre S_i e S_{j+1} (sem incluir esses dois genes). A nova região intergênica entre S_i e S_{j+1} terá o valor x . No grafo de adjacências, essa operação remove os vértices entre uma extremidade de S_i e uma extremidade de S_{j+1} (considerando as extremidades mais próximas) e remove todas as arestas incidentes nesses vértices. Além disso uma nova aresta é adicionada conectando




Figura 2.9: A representação de uma deleção genérica seguida da aplicação da deleção $\psi_{(4)}^{(\mathcal{C}, (S_2, S_3), (S_4, S_5))}$ aplicada em um genoma $\mathcal{G} = \{\mathcal{C}\} = \{(S, \check{S})\}$ resultando em um genoma $\mathcal{G}'$. Também são apresentados os grafos $\mathbb{AG}(\mathcal{G}, \mathcal{H})$ e $\mathbb{AG}(\mathcal{G}', \mathcal{H})$. As arestas afetadas pela operação estão em vermelho.

a extremidade de S_i com a extremidade de S_{j+1} , essa aresta recebe peso x . Para essa aresta, consideramos as extremidades conectadas as arestas removidas. Note que se $i = j$ a deleção remove apenas nucleotídeos da região intergênica $\check{S}_i$, nesse caso devemos ter $0 \leq x \leq \check{S}_i$. A Figura 2.9 apresenta um exemplo de uma operação de deleção.

Quando queremos falar de uma operação que pode ser de inserção ou deleção, ou seja, um rearranjo não conservativo que pode adicionar ou remover material genético, usaremos o termo *indel*.

Estamos interessados em encontrar o menor número de rearranjos de genomas necessários para transformar um genoma $\mathcal{G}$ em outro genoma $\mathcal{H}$. Em alguns casos não precisamos obter $\mathcal{H}$ exatamente, mas nos contentamos com um genoma $\mathcal{H}'$ completamente compatível com $\mathcal{H}$ a partir de alguma relação de compatibilidade. Os rearranjos que podem ser usados são dados por um modelo de rearranjo, que é um conjunto das operações de rearranjo permitidas. Por exemplo, podemos ter um modelo composto apenas por operações de reversão ou um modelo composto pelos eventos de reversão, transposição e indels.

DISTÂNCIA DE GENOMAS POR REARRANJOS (DR)

Entrada: Dois genomas $\mathcal{G}$ e $\mathcal{H}$, uma relação de compatibilidade completa e um modelo de rearranjos de genomas.

Saída: Uma sequência de tamanho mínimo de rearranjos do modelo capaz de transformar $\mathcal{G}$ em um genoma $\mathcal{H}'$, tal que $\mathcal{H}' \approx_C \mathcal{H}$.

Dependente das características dos genomas, pode ser necessário que o modelo permita alguma operação específica. Se os genomas não forem balanceados então o modelo deve incluir operações de indel. Nesse caso, exigimos que as inserções só possam inserir caracteres abundantes em $\mathcal{H}$ e as deleções só possam deletar caracteres abundantes em $\mathcal{G}$. Sem essa restrição poderíamos transformar um genoma no outro removendo todos os caracteres de $\mathcal{G}$ e inserindo todos os caracteres de $\mathcal{H}$. Essa restrição será assumida sempre que libarmos com uma operação de indel. Se os genomas tiverem múltiplos cromossomos e for necessário mover material genético entre cromossomos, o modelo deve incluir uma operação como DCJ que pode realizar esse movimento. Como os problemas de distância

de rearranjo dependem do modelo M adotado vamos usar a notação DR_M quando nos referirmos ao problema para um modelo específico. O tamanho da sequência obtida pelo problema DR_M é a *distância de rearranjos* que é denotada por $d_M(\mathcal{G}, \mathcal{H})$. Os seguintes modelos serão considerados neste trabalho:

- R : O modelo de rearranjo composto apenas pela operação de reversão.
- T : O modelo de rearranjo composto apenas pela operação de transposição.
- RT : O modelo de rearranjo composto pelas operações de reversão e transposição.
- D : O modelo de rearranjo composto apenas pela operação de DCJ.
- RI : O modelo de rearranjo composto pelas operações de reversão e indel.
- TI : O modelo de rearranjo composto pelas operações de transposição e indel.
- RTI : O modelo de rearranjo composto pelas operações de reversão, transposição e indel.
- DI : O modelo de rearranjo composto pelas operações de DCJ e indel.

2.4 Partições de Genomas

Nesta seção, veremos o conceito de partição de genomas, o que será útil para provarmos fatores de aproximação para alguns dos algoritmos que iremos apresentar.

Uma *partição* de um cromossomo $\mathcal{C} = (S, \check{S})$ é uma sequência $\mathbb{S}$ de subcromossomos de $\mathcal{C}$, tal que cada caractere de S está exatamente em um dos subcromossomos. Formalmente temos dois casos:

- Se $\mathcal{C}$ é linear, existe uma sequência $b_1 < b_2 < \dots < b_{|\mathbb{S}|-1}$ com $|\mathbb{S}| - 1$ inteiros entre 1 e $|S| - 1$, tal que $\mathbb{S}_1$ é o subcromossomo $\mathcal{C}_{[1, b_1]}$, $\mathbb{S}_i, \forall i : 2 \leq i \leq |\mathbb{S}| - 1$, é o subcromossomo $\mathcal{C}_{[b_{i-1}+1, b_i]}$ e $\mathbb{S}_{|\mathbb{S}|}$ é o subcromossomo $\mathcal{C}_{[b_{|\mathbb{S}|-1}+1, |S|]}$.
- Se $\mathcal{C}$ é circular:
 - Se $|\mathbb{S}| = 1$, então $\mathbb{S}_1 = \mathcal{C}$.
 - Se $|\mathbb{S}| > 1$, existe uma sequência $b_1 < b_2 < \dots < b_{|\mathbb{S}|}$ com $|\mathbb{S}|$ inteiros entre 1 e $|S|$, tal que $\mathbb{S}_i, \forall i : 1 \leq i \leq |\mathbb{S}| - 1$, é o subcromossomo $\mathcal{C}_{[b_i+1, b_{i+1}]}$ e $\mathbb{S}_{|\mathbb{S}|}$ é o subcromossomo $\mathcal{C}_{[b_{|\mathbb{S}|}+1, b_1]}$.

Chamamos cada região intergênica $\check{S}_{b_i}$ de um *breakpoint* de $\mathbb{S}$ e cada subcromossomo de $\mathbb{S}$ de um *bloco* de $\mathbb{S}$. A Figura 2.10 apresenta um exemplo de partição de um cromossomo.

Uma *partição* de um genoma $\mathcal{G}$ é uma sequência de subcromossomos $\mathbb{S}$ formada pela concatenação da partição de cada um de seus cromossomos. Essas sequências podem ser concatenadas em qualquer ordem.

Uma *partição direta comum* entre dois genomas $\mathcal{G}$ e $\mathcal{H}$ é um par de sequências $(\mathbb{S}, \mathbb{P})$ de subcromossomos, tal que:




Figura 2.10: A partição de um cromossomo $\mathcal{C}$. Os breakpoints são representados por linhas tracejadas. Essa partição tem 5 blocos.




Figura 2.11: Uma partição direta comum entre dois genomas $\mathcal{G}$ e $\mathcal{H}$. Os blocos comuns estão coloridos de acordo com uma bijeção entre eles. Os blocos exclusivos estão em branco. Os breakpoints estão representados por linhas tracejadas.

1. $\mathbb{S}$ é uma partição de $\mathcal{G}$;
2. $\mathbb{P}$ é uma partição de $\mathcal{H}$;
3. Existe uma bijeção π entre um conjunto $\mathbb{S}^\pi$ de subcromossomos de $\mathbb{S}$ e um conjunto $\mathbb{P}^\pi$ de subcromossomos de $\mathbb{P}$, tal que se $\pi(\mathbb{S}_i) = \mathbb{P}_j$, para $\mathbb{S}_i \in \mathbb{S}^\pi$ e $\mathbb{P}_j \in \mathbb{P}^\pi$, então $\mathbb{S}_i \approx_C \mathbb{P}_j$;
4. Se X é o conjunto de rótulos de $\mathbb{S}$ que não estão em $\mathbb{S}^\pi$ e Y é o conjunto de rótulos de $\mathbb{P}$ que não estão em $\mathbb{P}^\pi$, então $X \cap Y = \emptyset$.

A Figura 2.11 apresenta um exemplo de uma partição direta comum entre dois genomas.

Uma *partição reversa comum* entre dois genomas $\mathcal{G}$ e $\mathcal{H}$ é um par de sequências $(\mathbb{S}, \mathbb{P})$ de subcromossomos, tal que:

1. $\mathbb{S}$ é uma partição de $\mathcal{G}$;
2. $\mathbb{P}$ é uma partição de $\mathcal{H}$;
3. Existe uma bijeção π entre um conjunto $\mathbb{S}^\pi$ de subcromossomos de $\mathbb{S}$ e um conjunto $\mathbb{P}^\pi$ de subcromossomos de $\mathbb{P}$, tal que se $\pi(\mathbb{S}_i) = \mathbb{P}_j$, para $\mathbb{S}_i \in \mathbb{S}^\pi$ e $\mathbb{P}_j \in \mathbb{P}^\pi$, então $\mathbb{S}_i \approx_P \mathbb{P}_j$;
4. Se X é o conjunto de rótulos de $\mathbb{S}$ que não estão em $\mathbb{S}^\pi$ e Y é o conjunto de rótulos de $\mathbb{P}$ que não estão em $\mathbb{P}^\pi$, então $X \cap Y = \emptyset$.

A Figura 2.12 apresenta um exemplo de uma partição reversa comum entre dois genomas.

Quando o tipo de partição comum pode ser inferido pelo contexto ou quando uma afirmação é válida para ambos os tipos de partição comum, usamos apenas o termo partição comum. Um *bloco comum* de uma partição comum é um bloco de $\mathbb{S}^\pi$ ou de $\mathbb{P}^\pi$, os demais blocos são chamados de *blocos exclusivos*. Note que podem existir várias bijeções entre os blocos comuns de uma partição comum, quando temos uma correspondência entre cromossomos circulares, podemos ter múltiplos deslocamentos e no caso de compatibilidades parciais a bijeção não nos diz se os cromossomos são iguais ou o inverso um do outro.




Figura 2.12: Uma partição reversa comum entre dois genomas $\mathcal{G}$ e $\mathcal{H}$. Os blocos comuns estão coloridos de acordo com uma bijeção entre eles. Os blocos exclusivos estão em branco. Os breakpoints estão representados por linhas tracejadas.

Quando estamos interessados em uma bijeção específica, com deslocamentos e orientações de cromossomos predefinidas, temos uma *partição comum guiada* dada pela tripla $(\mathbb{S}, \mathbb{P}, \sigma)$, onde σ é uma dupla (π, χ) contendo uma bijeção π entre os blocos comuns de $\mathbb{S}$ e $\mathbb{P}$ e uma função χ que atribui uma orientação e um deslocamento a cada bloco comum.

O *custo* de uma partição comum $\mathcal{P} = (\mathbb{S}, \mathbb{P})$, denotado por $\text{custo}(\mathcal{P})$ (ou $\text{custo}((\mathbb{S}, \mathbb{P}))$) é o número de breakpoints de ambas as partições, ou seja, é a soma de número de breakpoints de $\mathbb{S}$ e de $\mathbb{P}$. Com essa definição de custo definimos os seguintes problemas de otimização. Note que só garantimos que dois genomas tem uma partição direta comum se os sinais dos caracteres com rótulos comuns forem iguais, caso contrário podemos não ter uma bijeção entre os blocos comuns. Para o nosso caso, será suficiente assumir que os genomas não tem sinais quando lidamos com partições diretas comuns.

PARTIÇÃO DIRETA COMUM MÍNIMA DE GENOMAS (PDCMG)

Entrada: Dois genomas sem sinais $\mathcal{G}$ e $\mathcal{H}$ e uma relação de compatibilidade.

Saída: Uma partição direta comum $(\mathbb{S}, \mathbb{P})$ entre $\mathcal{G}$ e $\mathcal{H}$ com custo mínimo.

PARTIÇÃO REVERSA COMUM MÍNIMA DE GENOMAS (PRCMG)

Entrada: Dois genomas $\mathcal{G}$ e $\mathcal{H}$ e uma relação de compatibilidade.

Saída: Uma partição reversa comum $(\mathbb{S}, \mathbb{P})$ entre $\mathcal{G}$ e $\mathcal{H}$ com custo mínimo.

Sempre que tratamos do problema PDCMG, assumimos que os genomas não tem sinais. Já quando tratamos do problema PRCMG, assumimos que os genomas pode ou não ter sinais, a menos que o caso seja especificado.

Uma propriedade importante do custo é dada pelo seguinte lema.

Lema 1. *Se dois genomas $\mathcal{G}$ e $\mathcal{H}$ são completamente compatíveis então existe uma partição comum direta entre eles de custo zero. Se os genomas forem balanceados a recíproca também é verdadeira.*

Demonstração. Se $\mathcal{G}$ e $\mathcal{H}$ são completamente compatíveis uma partição de $\mathcal{G}$ formada apenas por um bloco para cada cromossomo de $\mathcal{G}$ e uma partição de $\mathcal{H}$ formada apenas por um bloco para cada cromossomo de $\mathcal{H}$ é uma partição comum direta de custo zero. Por outro lado, se existe uma partição comum direta de custo zero, então não existem breakpoints, logo cada bloco corresponde a um dos cromossomos dos genomas originais. Se os genomas forem balanceados, só temos blocos comuns logo garantimos que os cromossomos são compatíveis. $\square$

Dada uma operação de rearranjo β e dois genomas $\mathcal{G}$ e $\mathcal{H}$, seja $(\mathbb{S}, \mathbb{P})$ uma partição comum mínima entre $\mathcal{G}$ e $\mathcal{H}$ e $(\mathbb{S}', \mathbb{P}')$ uma partição comum mínima entre $\beta \circ \mathcal{G}$ e $\mathcal{H}$, usaremos $\Delta_{\text{custo}}(\beta, \mathcal{G}, \mathcal{H}) = \text{custo}((\mathbb{S}, \mathbb{P})) - \text{custo}((\mathbb{S}', \mathbb{P}'))$ para denotar a variação no custo da partição mínima antes e depois de aplicarmos β em $\mathcal{G}$.

2.5 Equivalência entre Correspondência de Genes, Empacotamentos por Ciclos e Partições Guiadas

Quando dois genomas sendo comparados em um problema de distância por rearranjos possuem apenas uma cópia de cada gene, os problemas tendem a admitir soluções mais simples. Em particular, os fatores de aproximação costumam ser menores quando essa restrição é adotada. Portanto, uma abordagem para lidar com problemas que apresentam mais de uma cópia de cada gene consiste em usar uma correspondência entre os genes dos dois genomas para transformá-los em um par de genomas com apenas uma cópia de cada gene. Quando os genomas têm a mesma quantidade de genes de um dado rótulo, essa correspondência nos dá uma bijeção entre esses genes. Caso existam genes abundantes em um dos genomas, alguns genes ficarão fora da correspondência, mas apenas o mínimo necessário para que a quantidade de genes de cada rótulo seja a mesma nos dois genomas. Esses genes que não estarão incluídos na correspondência são genes que serão deletados (quando no genoma de origem) ou inseridos (quando no genoma de destino).

Uma forma de buscar por mapeamentos que gerem melhores distâncias é observar como eles são representados no grafo de adjacências. Um *empacotamento por ciclos alternados* do grafo de adjacências é um conjunto de ciclos alternados, tal que:

- Todo vértice e aresta de adjacência pertence a exatamente um ciclo.
- Uma aresta de rótulo pertence a um ciclo somente se ela não tem uma aresta gêmea ou sua aresta gêmea também pertence a um ciclo.
- O número de arestas de caractere conectando vértices correspondentes a um caractere de $\mathcal{G}$ com rótulo α é exatamente $\max(0, \text{occ}(\alpha, \mathcal{G}) - \text{occ}(\alpha, \mathcal{H}))$.
- O número de arestas de caractere conectando vértices correspondentes a um caractere de $\mathcal{H}$ com rótulo α é exatamente $\max(0, \text{occ}(\alpha, \mathcal{H}) - \text{occ}(\alpha, \mathcal{G}))$.

Teorema 1. *Existe uma bijeção entre os empacotamentos por ciclos alternados do grafo de adjacências e as correspondências entre os genes de mesmo rótulo dos dois genomas.*

Demonstração. Dado um empacotamento do grafo de adjacências, podemos construir uma correspondência entre os genes seguindo as arestas de rótulo do empacotamento. A condição sobre as arestas gêmeas nos garante que essa construção é bem definida e as restrições sobre as arestas de caractere nos garantem que apenas a quantidade de genes necessária está fora da correspondência.

Por outro lado, dada uma correspondência podemos construir um empacotamento juntando as arestas de adjacência com arestas de rótulo ligando os genes correspondentes, usando duas arestas gêmeas por gene, e conectar os genes fora da correspondência com

arestas de caractere. Note que como estamos adicionando as duas arestas gêmeas a restrição sobre essas arestas é satisfeita. Além disso, como estamos adicionando arestas de caractere apenas para os genes fora da correspondência, a restrição sobre essas arestas também é satisfeita. $\square$

A bijeção dada pelo Teorema 1 motiva a seguinte definição que nos permite representar uma correspondência parcial entre genes de dois genomas. Dada uma correspondência $\mathcal{M}$ entre alguns genes de dois genomas $\mathcal{G}$ e $\mathcal{H}$, um *grafo de adjacências com caracteres fixos*, denotado por $\mathbb{AG}_{cf}(\mathcal{G}, \mathcal{H}, \mathcal{M})$, é um grafo de adjacências onde os vértices advindos dos caracteres na correspondência $\mathcal{M}$ são fixos, ou seja, as únicas arestas de rótulo incidentes nesses vértices são as arestas de rótulo que conectam esses vértices com os vértices correspondentes no outro genoma. Note que o grafo de adjacências com caracteres fixos é um subgrafo do grafo de adjacências original e o grafo original é um grafo de adjacências com caracteres fixos onde a correspondência é o conjunto vazio.

Veremos também como um subconjunto das partições guiadas é outra forma de representar uma correspondência entre os genes de dois genomas. Para uma dada partição comum guiada $(\mathbb{S}, \mathbb{P}, \sigma)$, de dois genomas $\mathcal{G}$ e $\mathcal{H}$, podemos construir uma correspondência entre os genes de mesmo rótulo dos dois genomas seguindo a bijeção, deslocamento e orientações dadas por σ para os blocos comuns de $\mathbb{S}$ e $\mathbb{P}$. Note que a restrição sobre os rótulos dos blocos exclusivos garante que essa construção é bem definida. Gostaríamos de ter uma bijeção entre as correspondências e as partições comuns guiadas, mas isso não é possível, pois várias partições guiadas podem resultar na mesma correspondência. No entanto, se restringirmos as partições guiadas para que elas sejam *partições comuns guiadas minimais*, ou seja, as de menor custo que geram a correspondência, então conseguimos uma bijeção. Note que toda partição comum guiada mínima é uma partição comum guiada minimal.

Teorema 2. *Existe uma bijeção entre as partições comuns guiadas minimais e as correspondências entre os genes de mesmo rótulo dos dois genomas.*

Demonstração. Pelo processo de construção descrito anteriormente, cada partição comum guiada minimal gera uma correspondência entre os genes de mesmo rótulo dos dois genomas. Por outro lado, dada uma correspondência entre os genes de mesmo rótulo dos dois genomas, podemos recuperar a partição comum guiada minimal correspondente a essa correspondência. Para isso, basta construir uma partição comum guiada que gere essa correspondência e onde os blocos são os maiores possíveis, ou seja, não deve haver dois blocos adjacentes que possam ser combinados. $\square$

Corolário 1. *Existe uma bijeção entre os empacotamentos por ciclos alternados do grafo de adjacências e as partições comuns guiadas minimais de dois genomas.*

Demonstração. O resultado segue diretamente dos teoremas 1 e 2. $\square$

Vamos usar as bijeções apresentadas nos teoremas 1 e 2, e no corolário 1, para definir uma correspondência canônica entre correspondências de genes, empacotamento por ciclos alternados e partições comuns guiadas minimais. Usando essa correspondência podemos determinar o custo de uma partição olhando para o empacotamento por ciclos alternados

correspondente a ela. Para isso vamos precisar dos seguintes valores. Seja $\mathcal{E}$ um empacotamento em ciclos alternados do grafo $\mathbb{AG}(\mathcal{G}, \mathcal{H})$. Temos que $cic(\mathcal{E})$ é o número de ciclos alternados compatíveis triviais limpos em $\mathcal{E}$ e $adjcar(\mathcal{E})$ é a quantidade de arestas de adjacência entre duas arestas de caractere em $\mathcal{E}$. Lembramos também que $|E_a|$ é a quantidade de arestas de adjacência em $\mathbb{AG}(\mathcal{G}, \mathcal{H})$.

Teorema 3. *Seja $\mathcal{P} = (\mathbb{S}, \mathbb{P}, \sigma)$ uma partição reversa comum guiada minimal entre dois genomas $\mathcal{G}$ e $\mathcal{H}$ e seja $\mathcal{E}$ o empacotamento por ciclos alternados do grafo de adjacências $\mathbb{AG}(\mathcal{G}, \mathcal{H})$ correspondente a essa partição. Temos que $\text{custo}(\mathcal{P}) = |E_a| - 2cic(\mathcal{E}) - adjcar(\mathcal{E})$. De forma similar se $\mathcal{P}' = (\mathbb{S}', \mathbb{P}', \sigma')$ for uma partição direta comum guiada minimal e $\mathcal{E}'$ for o empacotamento por ciclos alternados do grafo de adjacências correspondente a essa partição. Temos que $\text{custo}(\mathcal{P}') = |E_a| - 2cic(\mathcal{E}') - adjcar(\mathcal{E}')$.*

Demonstração. Lembre que o custo da partição é dado pelo número de breakpoints. Como cada breakpoint está entre dois caracteres ele terá uma aresta de adjacência correspondente a ele. Portanto, o custo da partição é a quantidade de arestas de adjacência no grafo menos as arestas de adjacência que não são breakpoints. As arestas de adjacência que não são breakpoints são as arestas de adjacência entre caracteres de um mesmo bloco. Se o bloco é comum, essas arestas estão em ciclos alternados triviais limpos. Teremos duas arestas para cada um desses ciclos: uma no genoma $\mathcal{G}$ e outra no genoma $\mathcal{H}$. Se o bloco é exclusivo, essas arestas estão entre duas arestas de caractere. Portanto, o número de arestas de adjacência que não são breakpoints é dado por $2cic(\mathcal{E}) + adjcar(\mathcal{E})$. O mesmo raciocínio vale para partições reversas e diretas. $\square$

O cálculo do custo se torna mais simples se os genomas forem balanceados.

Corolário 2. *Seja $\mathcal{P} = (\mathbb{S}, \mathbb{P}, \sigma)$ uma partição reversa comum guiada minimal entre dois genomas balanceados $\mathcal{G}$ e $\mathcal{H}$ e seja $\mathcal{E}$ o empacotamento por ciclos alternados do grafo de adjacências $\mathbb{AG}(\mathcal{G}, \mathcal{H})$ correspondente a essa partição. Temos que $\text{custo}(\mathcal{P}) = |E_a| - 2cic(\mathcal{E})$. De forma similar se $\mathcal{P}' = (\mathbb{S}', \mathbb{P}', \sigma')$ for uma partição direta comum guiada minimal e $\mathcal{E}'$ for o empacotamento por ciclos alternados do grafo de adjacências correspondente a essa partição. Temos que $\text{custo}(\mathcal{P}') = |E_a| - 2cic(\mathcal{E}')$.*

Demonstração. Adaptação do teorema 3 para o caso balanceado. Note que nesse caso não precisamos considerar blocos exclusivos. $\square$

A seguir apresentamos alguns conceitos e definições que usam o grafo de adjacência para representar as partições. Dizemos que dois ciclos triviais limpos do grafo de adjacências são *contínuos* se cada um deles contém uma aresta de um par de arestas gêmeas. Se os caracteres dos vértices conectados por essas arestas gêmeas têm o mesmo sinal, dizemos que os ciclos são *diretamente contínuos*. Considere uma ordem das arestas de adjacência em cada cromossomo de $\mathcal{G}$ induzida pela ordem dos genes nesse cromossomo. Ordene os ciclos triviais limpos por essa ordem das arestas. Definimos uma *sequência de ciclos contínuos* (ou *sequência de ciclos diretamente contínuos*) como uma sequência de ciclos dessa ordem onde cada par consecutivo de ciclos é contínuo (ou diretamente contínuo). Note que cada subcromossomo com tamanho pelo menos dois corresponde a uma

sequência de arestas de adjacência do grafo de adjacências. Portanto, dois subcromossomos parcialmente compatíveis de dois genomas $\mathcal{G}$ e $\mathcal{H}$ correspondem a uma sequência de ciclos contínuos e dois subcromossomos completamente compatíveis correspondem a uma sequência de ciclos diretamente contínuos.

Uma propriedade útil dessa relação entre compatibilidade dos subcromossomos e ciclos contínuos é que, se removermos uma aresta de adjacência do grafo de adjacências então qualquer partição gerada a partir desse grafo terá um breakpoint na região intergênica correspondente a essa aresta. Um grafo de adjacências com arestas de adjacência removidas é chamado de *grafo de adjacências com breakpoints fixos*. Note que o grafo de adjacências original é um grafo de adjacências com breakpoints fixos, onde nenhuma aresta de adjacência foi removida. Duas partições $\mathbb{S}$ de $\mathcal{G}$ e $\mathbb{P}$ de $\mathcal{H}$ podem ser representadas por um grafo de adjacências com breakpoints fixos, que denotaremos $\mathbb{AG}_{bf}(\mathbb{S}, \mathbb{P})$, onde as arestas de adjacência correspondentes aos breakpoints de $\mathbb{S}$ e $\mathbb{P}$ foram removidas.

Temos também o grafo de adjacências com breakpoints e caracteres fixos, denotado por $\mathbb{AG}_{bcf}(\mathbb{S}, \mathbb{P}, \mathcal{M})$, que é um grafo de adjacências com breakpoints fixos (com arestas de adjacência removidas) e um grafo de adjacências com caracteres fixos (com arestas de rótulo fixas). Esse grafo é útil para representar partições comuns entre dois genomas com caracteres fixos. Note que o grafo de adjacências original é um grafo de adjacências com breakpoints e caracteres fixos, onde nenhuma aresta de adjacência foi removida e nenhuma aresta de rótulo foi fixada. Da mesma forma o grafo de adjacências com breakpoints fixos e o grafo de adjacências com caracteres fixos são casos particulares desse grafo.

Capítulo 3

Partição de Genomas

Neste capítulo, focamos em relacionar os problemas de partição de genomas com problemas de rearranjo e em descrever soluções para o problema de partição de genomas. Apresentamos um algoritmo que garante uma aproximação quando os genomas são balanceados, um algoritmo exato que garante que esse problema é FPT considerando o custo da partição e um conjunto de heurísticas.

3.1 Relações entre Problemas de Partição de Genomas e Problemas de Rearranjo de Genomas

O objetivo desta seção é apresentar relações entre os problemas de partição de genomas e os problemas de rearranjo de genomas. Essas relações nos permitem usar os algoritmos de partição como sub-rotina dos algoritmos de rearranjo de forma a aproveitar os resultados teóricos obtidos. Em particular, podemos converter aproximações de um problema para o outro.

Lema 2. *Dados dois genomas $\mathcal{G}$ e $\mathcal{H}$, e considerando que inserções só podem inserir caracteres abundantes em $\mathcal{H}$ e as deleções só podem deletar caracteres abundantes em $\mathcal{G}$, temos as seguintes restrições para o valor de Δ_{custo} :*

- $|\Delta_{\text{custo}}(\rho, \mathcal{G}, \mathcal{H})| \leq 4$ para qualquer reversão ρ ;
- $|\Delta_{\text{custo}}(\tau, \mathcal{G}, \mathcal{H})| \leq 6$ para qualquer transposição τ ;
- $|\Delta_{\text{custo}}(\delta, \mathcal{G}, \mathcal{H})| \leq 4$ para qualquer DCJ δ ;
- $|\Delta_{\text{custo}}(\phi, \mathcal{G}, \mathcal{H})| \leq 3$ para qualquer inserção ϕ ;
- $|\Delta_{\text{custo}}(\psi, \mathcal{G}, \mathcal{H})| \leq 3$ para qualquer deleção ψ .

Demonstração. Note que podemos nos concentrar apenas no valor mínimo de Δ_{custo} , pois o valor máximo é simétrico a ele. Isso se dá pelo fato de que as operações de rearranjo são reversíveis, ou seja, para cada operação existe uma operação inversa que desfaz a operação original. Dessa forma, se uma operação pode aumentar o custo em x indo de $\mathcal{G}$ para $\mathcal{H}$, a operação inversa pode diminuir o custo em x indo de $\mathcal{H}$ para $\mathcal{G}$.

Considere a partição comum mínima $\mathcal{P}$ de $\mathcal{G}$ e $\mathcal{H}$ e o empacotamento por ciclos alternados $\mathcal{E}$ correspondente a essa partição.

Uma reversão remove duas arestas de adjacência e adiciona outras duas arestas de adjacência. Portanto, apenas os ciclos envolvendo essas arestas serão alterados. Consequentemente, qualquer alteração no custo da partição deve vir desses ciclos. Observando a fórmula para o custo ($\text{custo}(\mathcal{P}) = |E_a| - 2\text{cic}(\mathcal{E}) - \text{adjcar}(\mathcal{E})$) sabemos que a maior redução no custo ocorre ao produzirmos uma nova partição mínima com mais ciclos triviais compatíveis (aumentando o valor de $\text{cic}(\mathcal{E})$). Ou seja, queremos alterar as sequências de ciclos contínuos, pois essas definem os ciclos triviais pertencentes à partição. Portanto, inserirmos novos ciclos triviais compatíveis, combinando até quatro sequências de ciclos contínuos (dois para cada aresta removida) em no mínimo duas sequências de ciclos contínuos (cada uma formada ao combinarmos dois caminhos com as arestas adicionadas). Lembrando que essas combinações correspondem a combinar blocos das partições. Como adicionamos dois ciclos e cada um reduz em dois o valor do custo temos $|\Delta \text{custo}(\rho, \mathcal{G}, \mathcal{H})| \leq 4$. Um raciocínio similar pode ser aplicado para transposições e operações de DCJ, considerando que uma transposição remove três arestas de adjacência e adiciona outras três e um DCJ remove duas arestas de adjacência e adiciona outras duas.

No caso da inserção de x caracteres, para cada caractere inserido adicionamos uma aresta de adjacência (aumentando $|E_a|$ em x). A alteração no custo deve levar em conta essas arestas inseridas. Olhando novamente a fórmula do custo, temos que a maior redução no custo ocorre quando conseguimos aumentar o número de ciclos triviais compatíveis. Entretanto, podemos gerar no máximo $x + 1$ tais ciclos (aumentando em $2x + 2$ o valor de $2\text{cic}(\mathcal{E})$), pois um ciclo pode ser gerado para cada par consecutivo de caracteres inseridos ou para cada par consecutivo formado entre um caractere inserido e um caractere adjacente à região onde a inserção foi realizada. Além disso, para cada par de caracteres (a, b) em $\mathcal{H}$ pertencente aos novos ciclos inseridos, ou ambos correspondem a arestas de caracteres ou existe um caractere em $\mathcal{G}$ correspondente a um deles (seja α o rótulo desse caractere). No primeiro caso, a inserção remove uma aresta de adjacência entre arestas de caracteres reduzindo em um o valor de $\text{adjcar}(\mathcal{E})$. No segundo caso, para que a inserção ocorra deve existir um outro caractere em $\mathcal{H}$ com rótulo α correspondente a uma aresta de caractere que vai deixar de ser uma aresta de caractere após a inserção, caso contrário estaríamos inserindo um caractere abundante em $\mathcal{G}$. Se não havia uma aresta de adjacência entre essa aresta de caractere e uma outra aresta de caractere, chegamos a uma contradição pois poderíamos ter uma partição menor deixando a e b como arestas de caracteres. Portanto, a inserção do par (a, b) reduz o valor de $\text{adjcar}(\mathcal{E})$ em pelo menos um. Considerando todos os pares inseridos, diminuimos o valor de $\text{adjcar}(\mathcal{E})$ em $x - 1$. Levando em conta o aumento de x em $|E_a|$ e de $2x + 2$ em $2\text{cic}(\mathcal{E})$ o custo pode ser reduzido em no máximo três.

No caso da deleção de x caracteres, para cada caractere removidos removemos uma aresta de adjacência (diminuindo o valor de $|E_a|$ em x). Note que uma deleção pode criar no máximo um ciclo trivial compatível, utilizando a aresta de adjacência adicionada após a deleção (esse ciclo pode diminuir o custo em 2). Além disso, para cada par de caracteres consecutivos (a, b) removidos em $\mathcal{G}$, ou eles correspondem a arestas de caracteres ou existe um caractere em $\mathcal{H}$ correspondente a um deles (seja α o rótulo desse caractere). No

primeiro caso, a remoção desse par de caracteres remove uma aresta de adjacência entre arestas de caracteres reduzindo em um o valor de $adjcar(\mathcal{E})$. No segundo caso, para que a deleção ocorra deve existir um outro caractere em $\mathcal{G}$ com rótulo α correspondente a uma aresta de caractere que vai deixar de ser uma aresta de caractere após a remoção, caso contrário estaríamos deletando um caractere abundante em $\mathcal{H}$. Se não havia uma aresta de adjacência entre essa aresta de caractere e uma outra aresta de caractere, chegamos a uma contradição pois poderíamos ter uma partição menor deixando a e b como arestas de caracteres. Portanto, a remoção do par (a, b) reduz o valor de $adjcar(\mathcal{E})$ em pelo menos um. Considerando todos os pares removidos, reduzimos o valor de $adjcar(\mathcal{E})$ em $x - 1$. Levando em conta a redução de x em $|E_a|$ e o aumento de 2 no valor de $2cic(\mathcal{E})$, o custo pode ser reduzido em no máximo três. $\square$

Lema 3. *Seja $(\mathbb{S}, \mathbb{P})$ uma partição comum de custo mínimo de dois genomas $\mathcal{G}$ e $\mathcal{H}$. Qualquer sequência de reversões, DCJ e indels que transforma $\mathcal{G}$ em um genoma completamente compatível com $\mathcal{H}$ deve ter tamanho pelo menos $\frac{custo((\mathbb{S}, \mathbb{P}))}{4}$.*

Demonstração. Sabemos pelo Lema 1 que após aplicarmos todas as operações em $\mathcal{G}$ teremos um genoma $\mathcal{G}'$, tal que existe uma partição comum $(\mathbb{S}', \mathbb{P}')$ de $\mathcal{G}'$ e $\mathcal{H}$ com $custo(\mathbb{S}', \mathbb{P}') = 0$. Pelo Lema 2, sabemos que cada reversão, DCJ ou indel pode diminuir o custo da partição mínima em no máximo 4. Portanto, a sequência de reversões, DCJ e indels deve ter tamanho pelo menos $\frac{custo((\mathbb{S}, \mathbb{P}))}{4}$. $\square$

Agora podemos usar os limitantes definidos até agora para provar relações entre aproximações para os problemas de partição de genomas e aproximações para os problemas de rearranjo de genomas. Perceba que as provas são genéricas em relação ao tipo de partição (direta ou reversa) e a existência ou não de sinais para os genes. Portanto, essas relações podem ser aplicadas para os dois tipos de partição e para genomas com ou sem sinais.

Teorema 4. *Dados dois genomas $\mathcal{G}$ e $\mathcal{H}$. Seja $(\mathbb{S}, \mathbb{P})$ uma partição comum de $\mathcal{G}$ e $\mathcal{H}$ obtida a partir de uma ℓ -aproximação para o problema PDCMG ou PRCMG. Se existe um algoritmo que encontre uma sequência com d_{RI} reversões e indels capaz de transformar $\mathcal{G}$ em um genoma completamente compatível com $\mathcal{H}$, tal que $d_{RI} \leq r \cdot \frac{custo((\mathbb{S}, \mathbb{P}))}{2}$ então esse algoritmo tem um fator de aproximação de $2\ell r$ para o problema DR_{RI} .*

Demonstração. Seja $(\mathbb{S}^*, \mathbb{P}^*)$ uma partição comum de $\mathcal{G}$ e $\mathcal{H}$ com custo mínimo. Pelo Lema 3, sabemos que qualquer sequência de reversões e indels que transforma $\mathcal{G}$ em um genoma completamente compatível com $\mathcal{H}$ deve ter tamanho pelo menos $\frac{custo((\mathbb{S}^*, \mathbb{P}^*))}{4}$, portanto $d_{RI} \geq \frac{custo((\mathbb{S}^*, \mathbb{P}^*))}{4}$. Como $(\mathbb{S}, \mathbb{P})$ é o resultado de uma ℓ -aproximação, temos que $custo((\mathbb{S}, \mathbb{P})) \leq \ell \cdot custo((\mathbb{S}^*, \mathbb{P}^*))$. Dessa forma $d_{RI} \leq r \cdot \frac{custo((\mathbb{S}, \mathbb{P}))}{2} \leq \ell r \cdot \frac{custo((\mathbb{S}^*, \mathbb{P}^*))}{2}$. Portanto o algoritmo tem um fator de aproximação de $2\ell r$. $\square$

Corolário 3. *Dados dois genomas balanceados $\mathcal{G}$ e $\mathcal{H}$. Seja $(\mathbb{S}, \mathbb{P})$ uma partição comum de $\mathcal{G}$ e $\mathcal{H}$ obtida a partir de uma ℓ -aproximação para o problema PDCMG ou PRCMG. Se existe um algoritmo que encontre uma sequência com d_R reversões capaz de transformar $\mathcal{G}$ em um genoma completamente compatível com $\mathcal{H}$, tal que $d_R \leq r \cdot \frac{custo((\mathbb{S}, \mathbb{P}))}{2}$ então esse algoritmo tem um fator de aproximação de $2\ell r$ para o problema DR_R .*

Demonstração. Segue diretamente do Teorema 4 ao considerarmos uma sequência apenas com reversões. $\square$

Teorema 5. *Dados dois genomas $\mathcal{G}$ e $\mathcal{H}$. Seja $(\mathbb{S}, \mathbb{P})$ uma partição comum de $\mathcal{G}$ e $\mathcal{H}$ obtida a partir de uma ℓ -aproximação para o problema PDCMG ou PRCMG. Se existe um algoritmo que encontre uma sequência com d_{DI} operações de DCJ e indels capaz de transformar $\mathcal{G}$ em um genoma completamente compatível com $\mathcal{H}$, tal que $d_{DI} \leq r \cdot \frac{\text{custo}((\mathbb{S}, \mathbb{P}))}{2}$ então esse algoritmo tem um fator de aproximação de $2\ell r$ para o problema DR_{DI} .*

Demonstração. Similar ao Teorema 4, mas usando DCJ no lugar de reversões. $\square$

Corolário 4. *Dados dois genomas balanceados $\mathcal{G}$ e $\mathcal{H}$. Seja $(\mathbb{S}, \mathbb{P})$ uma partição comum de $\mathcal{G}$ e $\mathcal{H}$ obtida a partir de uma ℓ -aproximação para o problema PDCMG ou PRCMG. Se existe um algoritmo que encontre uma sequência com d_D operações de DCJ capaz de transformar $\mathcal{G}$ em um genoma completamente compatível com $\mathcal{H}$, tal que $d_D \leq r \cdot \frac{\text{custo}((\mathbb{S}, \mathbb{P}))}{2}$ então esse algoritmo tem um fator de aproximação de $2\ell r$ para o problema DR_D .*

Demonstração. Segue diretamente do Teorema 5 ao considerarmos uma sequência apenas com operações de DCJ. $\square$

Lema 4. *Seja $(\mathbb{S}, \mathbb{P})$ uma partição comum de custo mínimo de dois genomas $\mathcal{G}$ e $\mathcal{H}$. Qualquer sequência de transposições, reversões e indels que transforma $\mathcal{G}$ em um genoma completamente compatível com $\mathcal{H}$ deve ter tamanho pelo menos $\frac{\text{custo}((\mathbb{S}, \mathbb{P}))}{6}$.*

Demonstração. Similar ao Lema 3, mas usando o fato de que cada transposição, reversão ou indel pode diminuir o custo da partição mínima em no máximo 6. $\square$

Teorema 6. *Dados dois genomas $\mathcal{G}$ e $\mathcal{H}$. Seja $(\mathbb{S}, \mathbb{P})$ uma partição comum de $\mathcal{G}$ e $\mathcal{H}$ obtida a partir de uma ℓ -aproximação para o problema PDCMG ou PRCMG. Se existe um algoritmo que encontre uma sequência com d_{RTI} reversões, transposições e indels capaz de transformar $\mathcal{G}$ em um genoma completamente compatível com $\mathcal{H}$, tal que $d_{RTI} \leq r \cdot \frac{\text{custo}((\mathbb{S}, \mathbb{P}))}{2}$ então esse algoritmo tem um fator de aproximação de $3\ell r$ para o problema DR_{RTI} .*

Demonstração. Similar ao Teorema 4, mas usando o Lema 4 no lugar do Lema 3. $\square$

Corolário 5. *Dados dois genomas $\mathcal{G}$ e $\mathcal{H}$. Seja $(\mathbb{S}, \mathbb{P})$ uma partição comum de $\mathcal{G}$ e $\mathcal{H}$ obtida a partir de uma ℓ -aproximação para o problema PDCMG ou PRCMG. Se existe um algoritmo que encontre uma sequência com d_{TI} transposições e indels capaz de transformar $\mathcal{G}$ em um genoma completamente compatível com $\mathcal{H}$, tal que $d_{TI} \leq r \cdot \frac{\text{custo}((\mathbb{S}, \mathbb{P}))}{2}$ então esse algoritmo tem um fator de aproximação de $3\ell r$ para o problema DR_{TI} .*

Demonstração. Segue diretamente do Teorema 6 ao considerarmos uma sequência apenas com transposições e indels. $\square$

Corolário 6. *Dados dois genomas balanceados $\mathcal{G}$ e $\mathcal{H}$. Seja $(\mathbb{S}, \mathbb{P})$ uma partição comum de $\mathcal{G}$ e $\mathcal{H}$ obtida a partir de uma ℓ -aproximação para o problema PDCMG ou PRCMG. Se existe um algoritmo que encontre uma sequência com d_{RT} reversões e transposições capaz de transformar $\mathcal{G}$ em um genoma completamente compatível com $\mathcal{H}$, tal que $d_{RT} \leq r \cdot \frac{\text{custo}((\mathbb{S}, \mathbb{P}))}{2}$ então esse algoritmo tem um fator de aproximação de $3\ell r$ para o problema DR_{RT} .*

Demonstração. Segue diretamente do Teorema 6 ao considerarmos uma sequência apenas com reversões e transposições. $\square$

Corolário 7. *Dados dois genomas balanceados $\mathcal{G}$ e $\mathcal{H}$. Seja $(\mathbb{S}, \mathbb{P})$ uma partição comum de $\mathcal{G}$ e $\mathcal{H}$ obtida a partir de uma ℓ -aproximação para o problema PDCMG ou PRCMG. Se existe um algoritmo que encontre uma sequência com d_T transposições capaz de transformar $\mathcal{G}$ em um genoma completamente compatível com $\mathcal{H}$, tal que $d_T \leq r \cdot \frac{\text{custo}((\mathbb{S}, \mathbb{P}))}{2}$ então esse algoritmo tem um fator de aproximação de $3\ell r$ para o problema DR_T .*

Demonstração. Segue diretamente do Teorema 6 ao considerarmos uma sequência apenas com transposições. $\square$

A Tabela 3.1 apresenta fatores de aproximação para problemas de rearranjo. Esses fatores são obtidos a partir dos resultados apresentados anteriormente e de algoritmos conhecidos da literatura. Os algoritmos usados para os problemas de rearranjo foram propostos para o caso em que cada gene possui apenas uma cópia e devido à forma como as operações são escolhidas em cada um deles podemos garantir que se usamos a correspondência entre os genes dada pela partição temos um valor para r conforme indicado na tabela. É importante ressaltar que embora a prova para esses valores de r seja direta ela não está presente explicitamente nos artigos originais. Portanto, essa tabela serve como referência para os fatores que podem ser obtidos, mas uma prova rigorosa deles deve incluir uma prova da garantia para o valor de r necessário. Os algoritmos foram descritos para um caso específico de genomas com ou sem sinais, e como o valor garantido para r depende do custo da partição, devemos levar em conta qual o tipo de partição e qual a relação de compatibilidade usada.

3.2 Balanceamento de Genomas

Uma dificuldade que surge ao tentarmos encontrar uma partição é determinar quais serão os blocos exclusivos. Nesta seção descrevemos uma heurística gulosa que busca minimizar o número de blocos exclusivos. O lema seguinte garante que após aplicarmos essa heurística podemos partir de um genoma balanceado para encontrar o restante da partição.

Lema 5. *Dada uma partição comum $(\mathbb{S}, \mathbb{P})$ de dois genomas $\mathcal{G}$ e $\mathcal{H}$. Se removermos todos os blocos exclusivos de $\mathbb{S}$ e de $\mathbb{P}$, as partições resultantes formam uma partição comum entre dois genomas balanceados $\mathcal{G}'$ e $\mathcal{H}'$, tal que $\mathcal{G}'$ contém todos os caracteres raros de $\mathcal{G}$ e $\mathcal{H}'$ contém todos os caracteres raros de $\mathcal{H}$.*

Demonstração. Polas propriedades de partição comum, blocos exclusivos têm apenas caracteres abundantes e contêm uma quantidade de caracteres abundantes igual à diferença entre as ocorrências nos dois genomas. Portanto, nenhum caractere raro é removido. Além disso, como temos uma bijeção entre os blocos comuns, os genomas resultantes serão necessariamente balanceados. $\square$

Tabela 3.1: Fatores de aproximação para problemas de rearranjo obtidos a partir de aproximações para problemas de partição. Devemos levar em conta o problema de rearranjo, a relação de compatibilidade, a presença ou não de sinais e o tipo de partição para determinar o melhor valor conhecido para r . Mostramos o fator de aproximação genérico (F.A. Gen.) obtido a partir dos teoremas (Teo.) e Corolários (Cor.) e o fator de aproximação obtido a partir do melhor valor conhecido para r (F.A. Obtido). Para cada valor de r colocamos a referência onde o algoritmo foi descrito.

Problema	Relação	Sinais	Partição	F.A. Gen.	r	F.A. Obtido
DR_R	trivial	Sim	Reversa	$2\ell r$ (Cor. 3)	1 [24]	2ℓ
DR_R	trivial	Não	Reversa	$2\ell r$ (Cor. 3)	1 [25]	2ℓ
DR_D	trivial	Sim	Reversa	$2\ell r$ (Cor. 4)	1 [42]	2ℓ
DR_{DI}	trivial	Sim	Reversa	$2\ell r$ (Teo. 5)	1 [12]	2ℓ
DR_{RI}	trivial	Sim	Reversa	$2\ell r$ (Teo. 4)	1 [41]	2ℓ
DR_{RI}	trivial	Não	Reversa	$2\ell r$ (Teo. 4)	1 [2]	2ℓ
DR_T	trivial	Sim	Direta	$3\ell r$ (Cor. 7)	1 [7]	3ℓ
DR_{RT}	trivial	Sim	Reversa	$3\ell r$ (Cor. 6)	1 [39]	3ℓ
DR_{RT}	trivial	Não	Reversa	$3\ell r$ (Cor. 6)	1 [39]	3ℓ
DR_{TI}	trivial	Sim	Direta	$3\ell r$ (Cor. 5)	1 [2]	3ℓ
DR_{RTI}	trivial	Sim	Reversa	$3\ell r$ (Teo. 6)	1 [2]	3ℓ
DR_R	igualdade	Sim	Reversa	$2\ell r$ (Cor. 3)	2 [15]	4ℓ
DR_R	igualdade	Não	Reversa	$2\ell r$ (Cor. 3)	2 [15]	4ℓ
DR_{RI}	igualdade	Sim	Reversa	$2\ell r$ (Teo. 4)	2 [3]	4ℓ
DR_T	igualdade	Não	Direta	$3\ell r$ (Cor. 7)	$3.5^*[31]$	10.5ℓ
DR_{RT}	igualdade	Sim	Reversa	$3\ell r$ (Cor. 6)	$\frac{4}{3}$ [13]	4ℓ
DR_{RT}	igualdade	Não	Reversa	$3\ell r$ (Cor. 6)	$\frac{3}{2}$ [15]	4.5ℓ
DR_{RTI}	igualdade	Sim	Reversa	$3\ell r$ (Teo. 6)	2 [3]	6ℓ
DR_R	intervalo	Sim	Reversa	$2\ell r$ (Cor. 3)	2 [14]	4ℓ
DR_R	intervalo	Não	Reversa	$2\ell r$ (Cor. 3)	2 [16]	4ℓ
DR_{RT}	intervalo	Sim	Reversa	$3\ell r$ (Cor. 6)	$\frac{3}{2}$ [14]	4.5ℓ

* Nesse caso se aceitarmos uma aproximação assintótica, obtemos um valor de $r = 3$ [37].

Para a heurística que iremos adotar, considere que um caractere abundante está disponível para ser adicionado a um bloco exclusivo se ele não estiver contido em nenhum bloco exclusivo já detectado e ao removermos todos os caractere já adicionados a blocos exclusivos, o caractere ainda é abundante. Dada essa definição, heurística consiste em encontrar a maior sequência de caracteres disponíveis em $\mathcal{G}$ ou $\mathcal{H}$, tal que ao adicionar cada caractere dessa sequência em um bloco exclusivo os demais caracteres continuam disponíveis. Em seguida é criado um bloco exclusivo com essa sequência. Repetimos esse processo até que não haja mais caracteres abundantes fora dos blocos exclusivos. Pelo Lema 5, sabemos que ao removermos os blocos exclusivos detectados por essa heurística, teremos um par de genomas balanceados.

3.3 Algoritmo de aproximação para Problemas de Partição de Genomas Balanceados

Nessa seção iremos requerer uma propriedade adicional para as relações de compatibilidade entre cromossomos. Os resultados só são válidos para relações de compatibilidade que possam ser calculada em tempo polinomial, o que é o caso de todas as relações de compatibilidade apresentadas nessa tese.

Considere as partições $\mathbb{S}$ e $\mathbb{P}$ de dois genomas balanceados $\mathcal{G}$ e $\mathcal{H}$. A partir do grafo $\text{AG}_{bf}(\mathbb{S}, \mathbb{P})$ definimos o *grafo de compatibilidade parcial de blocos* $\text{CB}_P(\mathbb{S}, \mathbb{P})$. O conjunto de vértices desse grafo é formado por todos os subcromossomos de tamanho pelo menos 2 em blocos de $\mathbb{S}$ ou $\mathbb{P}$, ou seja, cada vértice corresponde a uma sequência consecutiva de arestas de adjacência de $\text{AG}_{bf}(\mathbb{S}, \mathbb{P})$. Note que em particular cada aresta de adjacência de $\text{AG}_{bf}(\mathbb{S}, \mathbb{P})$ corresponde a um vértice de $\text{CB}_P(\mathbb{S}, \mathbb{P})$. Já o conjunto de arestas de $\text{CB}_P(\mathbb{S}, \mathbb{P})$ contém uma aresta $\{\mathcal{C}, \mathcal{C}'\}$ se $\mathcal{C}$ e $\mathcal{C}'$ estão em genomas distintos e $\mathcal{C} \approx_P \mathcal{C}'$, ou seja, as sequências de arestas correspondentes a $\mathcal{C}$ e $\mathcal{C}'$ pertencem a uma sequência de ciclos contínuos de $\text{AG}_{bf}(\mathbb{S}, \mathbb{P})$. Chamaremos as arestas de $\text{CB}_P(\mathbb{S}, \mathbb{P})$ de *arestas de compatibilidade* para distingui-las das arestas de $\text{AG}_{bf}(\mathbb{S}, \mathbb{P})$. Também definimos o *grafo de compatibilidade completa de blocos* $\text{CB}_C(\mathbb{S}, \mathbb{P})$, usando $\approx_C$ no lugar de $\approx_P$, ou seja, a sequência de ciclos deve ser diretamente contínua. Usamos o termo *grafo de compatibilidade de blocos* e a notação $\text{CB}(\mathbb{S}, \mathbb{P})$, quando não for necessário especificar se a compatibilidade é parcial ou completa. A Figura 3.1 apresenta um exemplo de grafo de compatibilidade de blocos.

O grafo de compatibilidade de blocos é bipartido, pois dois vértices correspondentes a subcromossomos de blocos de $\mathbb{S}$ nunca são conectados por arestas de compatibilidade, e o mesmo vale para subcromossomos de blocos de $\mathbb{P}$. Consequentemente as componentes conexas desses grafos também são bipartidas. Denotamos a componente conexa do grafo $\text{CB}(\mathbb{S}, \mathbb{P})$ que contém o subcromossomo $\mathcal{C}$ como $\text{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{C})$. Note que se $\mathbb{S}$ e $\mathbb{P}$ formarem uma partição comum de $\mathcal{G}$ e $\mathcal{H}$, cada componente conexa do grafo de compatibilidade de blocos admite um emparelhamento perfeito. Portanto, para criarmos uma partição comum, novos breakpoints devem ser adicionados, até que essa propriedade seja satisfeita. Lembrando que adicionar breakpoints corresponde a remover arestas de adjacência de $\text{AG}_{bf}(\mathbb{S}, \mathbb{P})$. Os resultados a seguir nos ajudarão a escolher quais breakpoints adicionar.

Vamos estender a definição de subcromossomos para componentes conexas de $\text{CB}(\mathbb{S}, \mathbb{P})$. Dizemos que $\text{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{C}) \subseteq \text{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{D})$ se $\mathcal{C} \subseteq \mathcal{D}$. Por exemplo, na Figura 3.1 temos $\mathbb{C}_2 \subseteq \mathbb{C}_5$. O lema seguinte garante que podemos usar uma escolha arbitrária para $\mathcal{C}$ e $\mathcal{D}$.

Lema 6. *Considere uma relação de compatibilidade e duas partições $\mathbb{S}$ e $\mathbb{P}$ de dois genomas $\mathcal{G}$ e $\mathcal{H}$. Dados dois subcromossomos $\mathcal{C}$ e $\mathcal{D}$ de blocos de $\mathbb{S}$ ou $\mathbb{P}$, se $\mathcal{C} \subseteq \mathcal{D}$ então para cada subcromossomo $\mathcal{D}'$ em $\text{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{D})$ existe um subcromossomo $\mathcal{C}'$ em $\text{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{C})$ tal que $\mathcal{C}' \subseteq \mathcal{D}'$.*

Demonstração. Faremos essa prova por indução no tamanho do caminho mais curto entre $\mathcal{D}$ e $\mathcal{D}'$ em $\text{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{D})$. Se o tamanho do caminho mais curto for 1, então $\mathcal{D}' = \mathcal{D}$ e $\mathcal{C}' = \mathcal{C}$ satisfaz a condição. Agora, suponha que o tamanho do caminho mais curto seja maior que 1. Considere um subcromossomo $\mathcal{D}''$ adjacente a $\mathcal{D}'$ em $\text{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{D})$ e que pertença a um caminho mais curto entre $\mathcal{D}$ e $\mathcal{D}'$. Pela hipótese de indução existe um subcromossomo




Figura 3.1: Dois genomas $\mathcal{G}$ e $\mathcal{H}$ seguidos de algumas componentes conexas do grafo de compatibilidade parcial de blocos $\mathbb{CB}_P(\mathbb{S}, \mathbb{P})$, sendo que é usada a 2-compatibilidade, $\mathbb{S}$ é composta pelos cromossomos de $\mathcal{G}$ e $\mathbb{P}$ é composta pelos cromossomos de $\mathcal{H}$. A figura mostra as cinco componentes conexas do grafo que não têm apenas um vértice. Alguns genes foram coloridos para ajudar a identificar os subcromossomos correspondentes aos vértices das componentes nos genomas. Estão representadas em vermelho as regiões intergênicas correspondentes às arestas de interseção entre $\mathcal{C}_2$ e $\mathcal{C}_5$.

$\mathcal{C}''$ em $\mathbb{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{C})$ tal que $\mathcal{C}'' \subseteq \mathcal{D}''$. Como $\mathcal{D}''$ é adjacente a $\mathcal{D}'$, temos que as arestas de $\mathcal{D}''$ e $\mathcal{D}'$ pertencem a uma sequência de ciclos contínuos. Usando as arestas de $\mathcal{C}''$ essa sequência nos fornece um subcromossomo $\mathcal{C}'$ de $\mathbb{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{C}'') = \mathbb{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{C})$ tal que $\mathcal{C}' \subseteq \mathcal{D}'$. $\square$

Se temos dois subcromossomos $\mathcal{C}$ e $\mathcal{D}$ com arestas de adjacência em comum, dizemos que as duas componentes $\mathbb{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{C})$ e $\mathbb{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{D})$ se intersectam. Chamaremos de arestas de interseção de $\mathbb{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{C})$ com respeito a $\mathbb{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{D})$ as arestas de adjacência que pertencem a ambas as componentes e as arestas de adjacência das componentes conexas dessas arestas de adjacência (quando vistas como vértices de $\mathbb{CB}(\mathbb{S}, \mathbb{P})$).

Seja $T_{\mathbb{S}, \mathbb{P}}$ o conjunto de componentes conexas de $\mathbb{CB}(\mathbb{S}, \mathbb{P})$ que não admitem emparelhamento perfeito. Denotaremos por $T_{\mathbb{S}, \mathbb{P}}^{\min}$ o conjunto de componentes minimais de $T_{\mathbb{S}, \mathbb{P}}$, dado por $T_{\mathbb{S}, \mathbb{P}}^{\min} = \{C \in T_{\mathbb{S}, \mathbb{P}} \mid C' \not\subseteq C, \forall C' \in T_{\mathbb{S}, \mathbb{P}} \text{ e } C' \neq C\}$.

Lema 7. Considere uma relação de compatibilidade e duas partições $\mathbb{S}$ e $\mathbb{P}$ de dois genomas $\mathcal{G}$ e $\mathcal{H}$. Para cada componente $\mathcal{C} \in \mathbf{T}_{\mathbb{S}, \mathbb{P}}^{\min}$ um dos seguintes fatos é verdadeiro:

1. $\mathcal{C}$ não tem interseção com nenhuma outra componente de $\mathbf{T}_{\mathbb{S}, \mathbb{P}}^{\min}$.
2. Existe pelo menos uma aresta de adjacência de $\mathcal{C}$ que é uma aresta de interseção com respeito a todas as outras componentes de $\mathbf{T}_{\mathbb{S}, \mathbb{P}}^{\min}$ que intersectam $\mathcal{C}$.

3. *Existem duas arestas de adjacência de $\mathbb{C}$, tal que para cada componente de $\mathbf{T}_{\mathbb{S},\mathbb{P}}^{\min}$ que intersecta $\mathbb{C}$, pelo menos uma dessas arestas é uma aresta de interseção com respeito a essa componente.*

Demonstração. Note que qualquer subcromossomo de uma componente de $\mathbf{T}_{\mathbb{S},\mathbb{P}}^{\min}$ que intersecte um subcromossomo $\mathcal{C}$ de $\mathbb{C}$ deve ter pelo menos uma aresta de adjacência que não pertença a $\mathcal{C}$, caso contrário ele seria um subcromossomo de $\mathcal{C}$ e portanto $\mathbb{C}$ não poderia pertencer a $\mathbf{T}_{\mathbb{S},\mathbb{P}}^{\min}$.

Vamos agora considerar dois casos. Primeiramente, considere que os cromossomos de $\mathbb{C}$ são circulares. Nesse caso nenhuma outra componente de $\mathbf{T}_{\mathbb{S},\mathbb{P}}^{\min}$ pode intersectar $\mathbb{C}$, pois não seria possível que um cromossomo intersecte um cromossomo de $\mathbb{C}$ sem ser subcromossomo desse cromossomo.

Agora considere que os cromossomos de $\mathbb{C}$ são lineares. Nesse caso vamos argumentar que se existe um cromossomo $\mathcal{C}'$ em uma componente de $\mathbf{T}_{\mathbb{S},\mathbb{P}}^{\min}$ que intersecta um cromossomo $\mathcal{C}$ de $\mathbb{C}$, então a primeira ou a última aresta de adjacência de $\mathcal{C}$ está nessa interseção. Como $\mathcal{C}'$ deve ter uma aresta de adjacência que não pertença a $\mathcal{C}$, essa aresta deve ser uma aresta do cromossomo que contém $\mathcal{C}$ e que esteja antes ou depois de $\mathcal{C}$. Como $\mathcal{C}'$ intersecta $\mathcal{C}$, $\mathcal{C}'$ também possui uma aresta de adjacência que pertence a $\mathcal{C}$. Portanto, como $\mathcal{C}'$ é contínuo, ele deve conter a primeira ou a última aresta de $\mathcal{C}$. $\square$

A partir do Lema 7, para cada componente conexa $\mathbb{C}$ de $\mathbf{T}_{\mathcal{G},\mathcal{H}}^{\min}$ ($\mathbf{T}_{\mathbb{S},\mathbb{P}}^{\min}$ onde $\mathbb{S}$ é composta pelos cromossomos de $\mathcal{G}$ e $\mathbb{P}$ é composta pelos cromossomos de $\mathcal{H}$) vamos construir um conjunto $\mathbf{B}_{\mathbb{C}}$ de arestas de adjacência que serão candidatas para serem removidas na hora de criar um breakpoint. Definiremos esse conjunto para cada caso do Lema 7:

1. Nesse caso, escolhemos uma aresta de adjacência qualquer e de um subcromossomo de $\mathbb{C}$ e o conjunto $\mathbf{B}_{\mathbb{C}}$ é formado pelas arestas da componente conexa de e (vista como um vértice de $\mathbb{CB}(\mathbb{S}, \mathbb{P})$).
2. Nesse caso, escolhemos uma aresta de adjacência e dentre as arestas de interseção descritas nesse caso e o conjunto $\mathbf{B}_{\mathbb{C}}$ é formado pelas arestas da componente conexa de e (vista como um vértice de $\mathbb{CB}(\mathbb{S}, \mathbb{P})$).
3. Vamos observar em conjunto todas as componentes do último caso. Para essas componentes, temos duas arestas de interseção descritas nesse caso. Vamos determinar as arestas escolhidas utilizando um problema de cobertura de vértices de um grafo G . Em G , para cada aresta de interseção entre duas componentes do último caso, criamos um vértice. Além disso, para cada componente $\mathbb{C}$ desse caso criamos uma aresta conectando os vértices correspondentes às duas arestas de interseção descritas nesse caso. O conjunto $\mathbf{B}_{\mathbb{C}}$ é formado pelas arestas das componentes conexas de cada componente $\mathbb{C}$ escolhidas pela solução do problema de cobertura de vértices de G .

Ao adicionarmos breakpoints o conjunto $\mathbf{T}_{\mathbb{S},\mathbb{P}}^{\min}$ poderá passar a ter novos elementos, mas esses elementos sempre terão alguma aresta de adjacência de $\mathbf{B}_{\mathbb{C}}$ para alguma componente $\mathbb{C}$ de $\mathbf{T}_{\mathcal{G},\mathcal{H}}^{\min}$. Portanto para componentes de $\mathbf{T}_{\mathbb{S},\mathbb{P}}^{\min}$ que não estejam em $\mathbf{T}_{\mathcal{G},\mathcal{H}}^{\min}$,

escolhemos $\mathbf{B}_C$ como o conjunto de arestas de adjacência de algum $\mathbf{B}_{C'}$ de alguma componente C' de $\mathbf{T}_{\mathcal{G},\mathcal{H}}^{\min}$.

O algoritmo 1 apresenta o pseudocódigo do algoritmo de aproximação para os problemas PDCMG e PRCMG. A diferença entre o uso desse algoritmo para os dois problemas é que no caso do PDCMG, o algoritmo usa uma relação de compatibilidade completa e deve retornar uma partição comum direta, enquanto no caso do PRCMG, o algoritmo usa uma relação de compatibilidade parcial e deve retornar uma partição comum reversa. Nesse algoritmo, começamos considerando $\mathcal{G}$ como uma partição de $\mathcal{G}$ e $\mathcal{H}$ como uma partição de $\mathcal{H}$ (cada cromossomo é um bloco). Em seguida usamos as estruturas descritas anteriormente para selecionar breakpoints a serem adicionados nessas partições até obtermos um conjunto $\mathbf{T}_{\mathbb{S},\mathbb{P}}^{\min}$ vazio. Em seguida, ainda podemos ter blocos de $\mathbb{S}$ sem correspondentes em $\mathbb{P}$ e vice-versa, ou seja, $\mathbb{S}$ e $\mathbb{P}$ ainda não formam uma partição comum. Para resolver isso, adicionaremos breakpoints pelo seguinte processo: Encontre o maior bloco $\mathcal{B}$ em $\mathbb{S}$ ou $\mathbb{P}$ sem correspondente; Encontre um bloco $\mathcal{D}$ da outra partição que contenha um subcromossomo de $\text{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{B})$ ou um caractere com mesmo rótulo do caractere de $\mathcal{B}$, caso $\mathcal{B}$ tenha apenas um caractere. Esse subcromossomo ou caractere deve existir pois a componente $\text{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{B})$ admite um emparelhamento perfeito e os genomas são balanceados; Adicione breakpoints em $\mathcal{D}$ ao redor do subcromossomo e repita o processo anterior caso $\mathbf{T}_{\mathbb{S},\mathbb{P}}^{\min}$ deixe de ser vazio. Repetimos esse processo até que tenhamos uma partição comum. Na Figura 3.2 temos um exemplo de execução do algoritmo.

Teorema 7. *Dados dois genomas balanceados $\mathcal{G}$ e $\mathcal{H}$, seja $k = \text{occ_max}(\mathcal{G})$. O Algoritmo 1 garante as seguintes aproximações:*

- $2k$: Para o problema PDCMG com uma representação sem sinais.
- $2k$: Para o problema PRCMG com uma representação com sinais.
- $4k$: Para o problema PRCMG com uma representação sem sinais.

Demonstração. Primeiramente, provamos que o algoritmo termina e gera uma partição comum. A cada iteração, o algoritmo deve adicionar pelo menos um breakpoint correspondente a uma aresta de adjacência ainda presente. Como o número total de ocorrências de arestas de adjacência é finito, o número de iterações é limitado por esse total. Quando nenhuma adjacência interna permanece, todos os blocos são unitários. Como os genomas são balanceados, esses blocos podem ser emparelhados, produzindo uma partição comum.

Agora provamos que o algoritmo encontra uma solução a um fator de $2k$ da solução ótima. Para isso determinamos quanto cada passo do algoritmo contribui para dois valores: um limitante superior L , representando um número de breakpoints maior ou igual ao adicionado pelo algoritmo; e um limitante inferior L^* , representando um número de breakpoint menor ou igual ao custo da partição mínima. Ou seja, $L \geq \text{custo}((\mathbb{S}, \mathbb{P}))$, onde $(\mathbb{S}, \mathbb{P})$ é a partição comum gerada pelo algoritmo e o $L^* \leq \text{custo}((\mathbb{S}^*, \mathbb{P}^*))$, onde $(\mathbb{S}^*, \mathbb{P}^*)$ é uma partição comum de custo mínimo.

Note que cada breakpoint adicionado em blocos de $\mathbf{T}_{\mathbb{S},\mathbb{P}}^{\min}$ que não estejam no $\mathbf{T}_{\mathcal{G},\mathcal{H}}^{\min}$, estão necessariamente em $\mathbf{B}_C$ de alguma componente C de $\mathbf{T}_{\mathcal{G},\mathcal{H}}^{\min}$. Isso é uma consequência de todos os novos elementos adicionados em $\mathbf{T}_{\mathbb{S},\mathbb{P}}^{\min}$ terem vindo de algum breakpoint

escolhido anteriormente e do algoritmo escolher breakpoints nos conjuntos $\mathbf{B}_{\mathbb{C}}$. O mesmo ocorre para breakpoints adicionados nos blocos $\mathcal{D}$ escolhidos. Além disso, o número de arestas de adjacência em cada conjunto $\mathbf{B}_{\mathbb{C}}$ é no máximo tk , onde:

- $t = 2$ se a relação de compatibilidade for parcial em uma representação com sinais ou se a relação de compatibilidade for completa, pois temos no máximo k ocorrências de cada rótulo em cada genoma e as arestas do mesmo conjunto $\mathbf{B}_{\mathbb{C}}$ têm vértices com rótulos iguais.
- $t = 4$ se a relação de compatibilidade for parcial em uma representação sem sinais, pois temos a mesma propriedade do caso anterior, mas agora cada ocorrência de um rótulo pode aparacer em duas arestas de adjacência diferentes. Isso ocorre pois podemos ter uma aresta de adjacência com os rótulos (x, y) e outra com os rótulos (y, x) .

Portanto, o algoritmo adiciona no máximo $L = tkL'$ breakpoints onde L' é a quantidade de breakpoints adicionados em blocos de $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$.

Verificamos agora os breakpoints adicionados em blocos de $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$. Vamos separar nos três casos do Lema 7:

1. Se uma componente de $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$ não tem interseção com nenhuma outra componente de $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$, então necessariamente deve haver um breakpoint em um bloco dessa componente em qualquer partição comum de $\mathcal{G}$ e $\mathcal{H}$. Portanto, contaremos um breakpoint para L^* e um breakpoint para L' .
2. Se uma componente $\mathbb{C}$ de $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$ contém uma aresta de adjacência que é uma aresta de interseção com respeito a todas as outras componentes de $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$ que intersectam $\mathbb{C}$, então adicionar breakpoints no conjunto $\mathbf{B}_{\mathbb{C}}$ é suficiente para eliminar de $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$ todas as componentes que contêm essa interseção. Além disso, pelo menos um breakpoint é necessário para eliminar essas componentes de $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$. Portanto, contaremos um breakpoint para L^* e um breakpoint para L' .
3. Cada componente $\mathbb{C}$ de $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$ desse último caso contém duas arestas de adjacência, tal que para cada componente de $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$ que intersecta $\mathbb{C}$, pelo menos uma dessas arestas é uma aresta de interseção com respeito a essa componente. Como os conjuntos $\mathbf{B}_{\mathbb{C}}$ para essas componentes foram construídos apartir de uma cobertura de vértices do grafo G , cada componentes é coberta por pelo menos uma aresta. Portanto, podemos garantir que adicionando breakpoints em $\mathbf{B}_{\mathbb{C}}$ para cada componente $\mathbb{C}$ desse último caso, eliminamos todas as componentes desse caso em $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$. Note que um conjunto mínimo de breakpoints que seja capaz de eliminar de $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$ todas as componentes do caso deve conter uma cobertura de vértices de G . Se usamos o algoritmo com fator dois para o problema de cobertura de vértices, então garantimos que adicionamos no máximo o dobro de breakpoints do que o necessário para eliminar essas componentes. Além disso, para cada breakpoint adicionado devemos ter pelo menos mais um breakpoint na mesma componente. Isso ocorre pois o par de caracteres ao redor desse breakpoint não era um elemento de $\mathbf{T}_{\mathcal{G}, \mathcal{H}}^{\min}$ (os subcromossomos das componentes do último caso devem ter pelo menos três caracteres para

que possa haver duas arestas de interseção), portanto deve haver mais um breakpoint para que esse par tenha a mesma ocorrência nas partições finais dos genomas. Portanto, se a cobertura de vértices mínima de G tem q breakpoints, adicionamos $2q$ breakpoints para L^* e $2q$ breakpoints para L' .

Ao considerarmos os três casos, temos que $L' = L^*$, portanto $L \leq tkL^*$. Como L é um limitante superior para o custo da partição comum gerada pelo algoritmo e L^* é um limitante inferior para o custo da partição comum de custo mínimo, temos que o algoritmo garante uma tk -aproximação. De acordo com os valores de t determinados anteriormente, temos que o algoritmo garante uma $2k$ -aproximação para o problema PDCMG com uma representação sem sinais, uma $2k$ -aproximação para o problema PRCMG com uma representação com sinais e uma $4k$ -aproximação para o problema PRCMG com uma representação sem sinais.

Por fim, provamos a complexidade polinomial do algoritmo. Seja n o número total de caracteres dos dois genomas. Há $O(n^2)$ subcromossomos. Se a compatibilidade entre dois subcromossomos pode ser testada em tempo polinomial, o grafo de compatibilidade pode ser construído em tempo polinomial, ainda que uma implementação direta teste $O(n^4)$ pares. Os emparelhamentos perfeitos e a cobertura de vértices aproximada também podem ser computados em tempo polinomial. Se cada iteração adiciona pelo menos um novo breakpoint, há $O(n)$ iterações. Portanto, o algoritmo é polinomial. $\square$

Algoritmo 1: $2k$ -aproximação para PDCMG e PRCMG

Entrada: Dois genomas balanceados $\mathcal{G}$ e $\mathcal{H}$ e uma relação de compatibilidade $\approx$

Saída: Uma partição comum de $\mathcal{G}$ e $\mathcal{H}$

```

1 início
2    $\mathbb{S} \leftarrow \mathcal{G}$ 
3    $\mathbb{P} \leftarrow \mathcal{H}$ 
4   Construa  $\mathbf{T}_{\mathbb{S}, \mathbb{P}}^{\min}$ 
5   Construa os conjuntos  $\mathbf{B}_C$  para cada componente  $C$  de  $\mathbf{T}_{\mathbb{S}, \mathbb{P}}^{\min}$ 
6   enquanto  $\mathbb{S}$  e  $\mathbb{P}$  não formarem uma partição comum faça
7     enquanto  $\mathbf{T}_{\mathbb{S}, \mathbb{P}}^{\min} \neq \emptyset$  faça
8        $\mathcal{X} \leftarrow$  subcromossomo em  $C \in \mathbf{T}_{\mathbb{S}, \mathbb{P}}^{\min}$ 
9        $C \leftarrow$  componente de  $\mathbf{T}_{\mathbb{S}, \mathbb{P}}^{\min}$  que contém  $\mathcal{X}$ 
10       $b \leftarrow$  breakpoint em  $\mathbf{B}_C$ 
11      Atualize  $\mathbb{S}$ ,  $\mathbb{P}$ ,  $\mathbf{T}_{\mathbb{S}, \mathbb{P}}^{\min}$  com  $b$ 
12    se houverem blocos em  $\mathbb{S}$  ou  $\mathbb{P}$  sem correspondentes então
13       $\mathcal{B} \leftarrow$  maior bloco em  $\mathbb{S}$  ou  $\mathbb{P}$  sem correspondente
14       $\mathcal{D} \leftarrow$  bloco em  $\mathbb{P}$  ou  $\mathbb{S}$  que contenha um subcromossomo de
         $\text{CCB}(\mathbb{S}, \mathbb{P}, \mathcal{B})$  ou um caractere com mesmo rótulo do caractere de  $\mathcal{B}$ ,
        caso  $\mathcal{B}$  tenha apenas um caractere
15      Atualize  $\mathbb{S}$ ,  $\mathbb{P}$  e  $\mathbf{T}_{\mathbb{S}, \mathbb{P}}^{\min}$  adicionando breakpoints em  $\mathcal{D}$  ao redor do
        subcromossomo
16  retorna  $(\mathbb{S}, \mathbb{P})$ 

```

- 3.4 Algoritmo Parametrizado para Problemas de Partição de Genomas
- 3.5 Heurísticas para Problemas de Partição de Genomas




Figura 3.2: Passos do algoritmo aplicados em dois genomas $\mathcal{G}$ e $\mathcal{H}$ cada um com apenas um cromossomo. Representamos os elementos de $\mathbf{T}_{\mathbb{S}, \mathbb{P}}^{min}$ por um dos subcromossomos da componente e marcamos os subcromossomos escolhidos e elementos de $\mathbf{T}_{\mathbb{S}, \mathbb{P}}^{min}$ correspondentes em vermelho. Nesse exemplo tornar $\mathbf{T}_{\mathbb{S}, \mathbb{P}}^{min}$ um conjunto vazio foi suficiente para gerar uma partição comum.

Capítulo 4

Empacotamento Máximo do Grafo de Adjacências por Ciclos Alternados

Esse capítulo é dedicado as heurísticas para o problema de Empacotamento Máximo do Grafo de Adjacências por Ciclos Alternados (EMGA).

4.1 Heurísticas para o Problema de Empacotamento Máximo do Grafo de Adjacências por Ciclos Alternados

4.1.1 Algoritmos de Empacotamento

Nesta seção, iremos discutir alguns algoritmos que podem ser usados para gerar um empacotamento de um grafo de adjacências. Assumimos que temos um grafo de adjacências com breakpoints e caracteres fixos para que esses algoritmos possam ser aplicados na versão mais geral do grafo.

Correspondência Aleatória

A estratégia mais simples que podemos adotar é gerar uma correspondência aleatória entre os caracteres dos dois genomas. Pelo Teorema ?? essa correspondência nos fornece um empacotamento por ciclos.

Busca em Largura

Outra estratégia que podemos adotar é usar buscas em largura para gerar um empacotamento. A ideia é realizar uma busca em largura a partir de um dos vértices do grafo para pegar o menor ciclo contendo esse vértice. Continuamos a realizar buscas para cada vértice do grafo que ainda não tenha sido adicionado a um ciclo. Um cuidado importante que devemos tomar é que, ao adicionar uma aresta de caractere a um ciclo sua aresta gêmeas devera ser usada em no empacotamento, portanto sempre fixamos os caracteres conectados por essas arestas gêmeas.

Seleção de Ciclos Pequenos

Nesta estratégia, usamos algoritmos para alguns subproblemas com o intuito de selecionar ciclos pequenos.

4.1.2 Empacotamento Aleatório

4.1.3 Algoritmo Genético

Os algoritmos genéticos [27] são uma técnica para o desenvolvimento de meta-heurísticas inspiradas no processo de evolução natural. Normalmente, tais algoritmos possuem os seguintes passos:

- Inicialização: Uma população inicial de soluções é gerada aleatoriamente ou por algum outro método.
- Avaliação: Cada solução na população é avaliada usando uma função de aptidão que mede a qualidade da solução.
- Seleção: Soluções são selecionadas para reprodução com base em sua aptidão. Soluções com maior aptidão têm maior probabilidade de serem selecionadas.
- Reprodução: Novas soluções (filhos) são geradas a partir das soluções selecionadas (pais) usando operadores genéticos como cruzamento (combinação de partes de dois pais) e mutação (alteração aleatória de partes de uma solução).
- Substituição: A nova geração de soluções substitui a antiga, e o processo se repete a partir do passo de avaliação.
- Elitismo: A melhor solução da geração atual é mantida para a próxima geração, garantindo que a qualidade não diminua.

Capítulo 5

Conclusão

Bibliografia

- [1] Alexsandro Oliveira Alexandrino, Klairton Lima Brito, Andre Rodrigues Oliveira, Ulisses Dias e Zaroni Dias. “A 1.375-Approximation Algorithm for Sorting by Transpositions with Faster Running Time”. Em: *Advances in Bioinformatics and Computational Biology*. Cham: Springer Nature Switzerland, 2022, pp. 147–157.
- [2] Alexsandro Oliveira Alexandrino, Andre Rodrigues Oliveira, Ulisses Dias e Zaroni Dias. “Genome Rearrangement Distance with Reversals, Transpositions, and Indels”. Em: *Journal of Computational Biology* 28.3 (mar. de 2021), pp. 235–247.
- [3] Alexsandro Oliveira Alexandrino, Andre Rodrigues Oliveira, Ulisses Dias e Zaroni Dias. “Incorporating intergenic regions into reversal and transposition distances with indels”. Em: *Journal of Bioinformatics and Computational Biology* 19.06 (nov. de 2021), p. 2140011.
- [4] Alexsandro Oliveira Alexandrino, Andre Rodrigues Oliveira, Ulisses Dias e Zaroni Dias. “Labeled Cycle Graph for Transposition and Indel Distance”. Em: *Journal of Computational Biology* 29.3 (mar. de 2022), pp. 243–256.
- [5] David A. Bader, Bernard M.E. Moret e Mi Yan. “A Linear-Time Algorithm for Computing Inversion Distance between Signed Permutations with an Experimental Study”. Em: *Journal of Computational Biology* 8.5 (out. de 2001), pp. 483–491.
- [6] Vineet Bafna e Pavel A. Pevzner. “Genome Rearrangements and Sorting by Reversals”. Em: *SIAM Journal on Computing* 25.2 (abr. de 1996), pp. 272–289.
- [7] Vineet Bafna e Pavel A. Pevzner. “Sorting by Transpositions”. Em: *SIAM Journal on Discrete Mathematics* 11.2 (mai. de 1998), pp. 224–240.
- [8] Anne Bergeron, Julia Mixtacki e Jens Stoye. “A Unifying View of Genome Rearrangements”. Em: *Algorithms in Bioinformatics*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2006, pp. 163–173.
- [9] Piotr Berman, Sridhar Hannenhalli e Marek Karpinski. “1.375-Approximation Algorithm for Sorting by Reversals”. Em: *Proceedings of the 10th Annual European Symposium on Algorithms (ESA 2002)*. Berlin, Heidelberg: Springer-Verlag, 2002, pp. 200–210.
- [10] Piotr Berman e Marek Karpinski. “On Some Tighter Inapproximability Results (Extended Abstract)”. Em: *Automata, Languages and Programming*. Vol. 1644. Lecture Notes in Computer Science. London, UK: Springer Berlin Heidelberg, 1999, pp. 200–209.

- [11] Sangeeta Bhatia, Pedro Feijão e Andrew Francis. “Position and Content Paradigms in Genome Rearrangements: The Wild and Crazy World of Permutations in Genomics”. Em: *Bulletin of Mathematical Biology* 80 (set. de 2016), pp. 3227–3246.
- [12] Marília D.V. Braga, Eyla Willing e Jens Stoye. “Double Cut and Join with Insertions and Deletions”. Em: *Journal of Computational Biology* 18.9 (set. de 2011), pp. 1167–1184.
- [13] Klairton L. Brito, Andre R. Oliveira, Alexsandro O. Alexandrino, Ulisses Dias e Zanoni Dias. “An improved approximation algorithm for the reversal and transposition distance considering gene order and intergenic sizes”. Em: *Algorithms for Molecular Biology* 16.1 (dez. de 2021), pp. 1–21.
- [14] Klairton Lima Brito, Alexsandro Oliveira Alexandrino, Andre Rodrigues Oliveira, Ulisses Dias e Zanoni Dias. “Genome Rearrangement Distance with a Flexible Intergenic Regions Aspect”. Em: *IEEE/ACM Transactions on Computational Biology and Bioinformatics* 20.3 (2023), pp. 1641–1653.
- [15] Klairton Lima Brito, Géraldine Jean, Guillaume Fertin, Andre Rodrigues Oliveira, Ulisses Dias e Zanoni Dias. “Sorting by Genome Rearrangements on Both Gene Order and Intergenic Sizes”. Em: *Journal of Computational Biology* 27.2 (fev. de 2020), pp. 156–174.
- [16] Klairton Lima Brito, Andre Rodrigues Oliveira, Alexsandro Oliveira Alexandrino, Ulisses Dias e Zanoni Dias. “Reversal and Transposition Distance of Genomes Considering Flexible Intergenic Regions”. Em: *Proceedings of the XI Latin and American Algorithms, Graphs and Optimization Symposium (LAGOS’2021)*. Procedia Computer Science, Elsevier, 2021, pp. 21–29.
- [17] Laurent Bulteau, Guillaume Fertin e Irena Rusu. “Sorting by Transpositions Is Difficult”. Em: *SIAM Journal on Discrete Mathematics* 26.3 (jan. de 2012), pp. 1148–1180.
- [18] Laurent Bulteau e Mathias Weller. “Parameterized Algorithms in Bioinformatics: An Overview”. Em: *Algorithms* 12 (dez. de 2019), p. 256.
- [19] Alberto Caprara. “Sorting Permutations by Reversals and Eulerian Cycle Decompositions”. Em: *SIAM Journal on Discrete Mathematics* 12.1 (jan. de 1999), pp. 91–110.
- [20] Xin Chen. “On sorting unsigned permutations by double-cut-and-joins”. Em: *Journal of Combinatorial Optimization* 25.3 (dez. de 2010), pp. 339–351.
- [21] Isaac Elias e Tzvika Hartman. “A 1.375-Approximation Algorithm for Sorting by Transpositions”. Em: *IEEE/ACM Transactions on Computational Biology and Bioinformatics* 3.4 (out. de 2006), pp. 369–379.
- [22] Guillaume Fertin, Anthony Labarre, Irena Rusu, Eric Tannier e Stéphane Vialette. *Combinatorics of Genome Rearrangements*. 1^a ed. Computational Molecular Biology. London, England: The MIT Press, 2009.

- [23] Yijie Han. “Improving the Efficiency of Sorting by Reversals”. Em: *Proceedings of the 2006 International Conference on Bioinformatics & Computational Biology (BI-OCOMP’2006)*. 2006, pp. 635–646.
- [24] Sridhar Hannenhalli e Pavel A. Pevzner. “Transforming cabbage into turnip. polynomial algorithm for sorting signed permutations by reversals”. Em: *Journal of ACM* 46.1 (jan. de 1999), pp. 1–27.
- [25] John Kececioğlu e David Sankoff. “Exact and approximation algorithms for the inversion distance between two chromosomes”. Em: *Combinatorial Pattern Matching. CPM’1993*. Berlin, Heidelberg: Springer Berlin Heidelberg, 1993, pp. 87–105.
- [26] Nadia El-Mabrouk e David Sankoff. “Analysis of Gene Order Evolution Beyond Single-Copy Genes”. Em: *Evolutionary Genomics. Methods in Molecular Biology (Methods and Protocols)* 855 (mai. de 2012), pp. 397–429.
- [27] Melanie Mitchell. *Introduction to Genetic Algorithms*. Cambridge, MA, USA: Springer Berlin Heidelberg, 2008.
- [28] Andre Rodrigues Oliveira, Klairton Lima Brito, Alexsandro Oliveira Alexandrino, Gabriel Siqueira, Ulisses Dias e Zanoni Dias. “Rearrangement Distance Problems: An updated survey”. Em: *ACM Computing Surveys* 56.8 (abr. de 2024).
- [29] Andre Rodrigues Oliveira, Klairton Lima Brito, Ulisses Dias e Zanoni Dias. “On the Complexity of Sorting by Reversals and Transpositions Problems”. Em: *Journal of Computational Biology* 26.11 (nov. de 2019), pp. 1223–1229.
- [30] Andre Rodrigues Oliveira, Geraldine Jean, Guillaume Fertin, Klairton Lima Brito, Laurent Bulteau, Ulisses Dias e Zanoni Dias. “Sorting Signed Permutations by Intergenic Reversals”. Em: *IEEE/ACM Transactions on Computational Biology and Bioinformatics* 18.6 (2021), pp. 2870–2876.
- [31] Andre Rodrigues Oliveira, Géraldine Jean, Guillaume Fertin, Klairton Lima Brito, Ulisses Dias e Zanoni Dias. “A 3.5-Approximation Algorithm for Sorting by Intergenic Transpositions”. Em: *Proceedings of the 7th International Conference on Algorithms for Computational Biology (AlCoB’2020)*. Springer International Publishing, 2020, pp. 16–28.
- [32] Christos Papadimitriou e Kenneth Steiglitz. *Combinatorial Optimization: Algorithms and Complexity*. Vol. 32. Jan. de 1982.
- [33] Atif Rahman, Swakkhar Shatabda e Masud Hasan. “An approximation algorithm for sorting by reversals and transpositions”. Em: *Journal of Discrete Algorithms* 6.3 (set. de 2008), pp. 449–457.
- [34] Mingfu Shao e Yu Lin. “Approximating the edit distance for genomes with duplicate genes under DCJ, insertion and deletion”. Em: *BMC Bioinformatics* 13.S19 (2012).
- [35] Mingfu Shao, Yu Lin e Bernard Moret. “An Exact Algorithm to Compute the DCJ Distance for Genomes with Duplicate Genes”. Em: *Research in Computational Molecular Biology*. Cham: Springer International Publishing, 2014, pp. 280–292.

- [36] Luiz Augusto Garcia da Silva, Luis Kowada, Noraí Romeu Rocco e Maria Emilia M.T. Walter. *An algebraic 1.375-approximation algorithm for the Transposition Distance Problem*. 2020.
- [37] Gabriel Siqueira, Alessandro Oliveira Alexandrino, Andre Rodrigues Oliveira e Zanoni Dias. “Approximation algorithm for rearrangement distances considering repeated genes and intergenic regions”. Em: *Algorithms for Molecular Biology* 16.1 (out. de 2021), p. 21.
- [38] Eric Tannier, Anne Bergeron e Marie-France Sagot. “Advances on sorting by reversals”. Em: *Discrete Applied Mathematics* 155.6-7 (abr. de 2007), pp. 881–888.
- [39] Maria Emília M.T. Walter, Zanoni Dias e João Meidanis. “Reversal and transposition distance of linear chromosomes”. Em: *Proceedings of the String Processing and Information Retrieval: A South American Symposium (SPIRE’1998)*. Los Alamitos, CA, USA, 1998, pp. 96–102.
- [40] Geoffrey A. Watterson, Warren J. Ewens, Thomas E. Hall e Alexander Morgan. “The chromosome inversion problem”. Em: *Journal of Theoretical Biology* 99.1 (nov. de 1982), pp. 1–7.
- [41] Eylia Willing, Jens Stoye e Marilia Braga. “Computing the Inversion-Indel Distance”. Em: *IEEE/ACM Transactions on Computational Biology and Bioinformatics* 18.06 (nov. de 2021), pp. 2314–2326.
- [42] Sophia Yancopoulos, Oliver Attie e Richard Friedberg. “Efficient sorting of genomic permutations by translocation, inversion and block interchange”. Em: *Bioinformatics* 21.16 (jun. de 2005), pp. 3340–3346.
- [43] Ron Zeira e Ron Shamir. “Genome Rearrangement Problems with Single and Multiple Gene Copies: A Review”. Em: *Bioinformatics and Phylogenetics*. Springer International Publishing, abr. de 2019, pp. 205–241.
- [44] David Zuckerman. “Linear Degree Extractors and the Inapproximability of Max Clique and Chromatic Number”. Em: *Theory of Computing* 3.6 (2007), pp. 103–128.